融合统计与机器学习的NIPT异常检测研究

摘　要

无创产前检测（NIPT）效果受孕周、BMI等因素影响。本文在现有临床数据基础上，构建统计与机器学习模型，对Y染色体浓度规律、最佳检测时点及异常判定方法进行探讨研究。

问题一中，为了探究胎儿Y染色体浓度与孕妇孕周、体重指数BMI等临床变量的关系，建立关系模型并检验其显著性。本文在男胎样本中，以Y染色体浓度的对数值为因变量，纳入BMI、孕周、年龄与胎儿健康状态构建多元线性回归模型。采用t检验与F检验评估个别与整体显著性，并使用HC3稳健标准误修正标准误与置信区间。通过QQ图和残差-拟合图进行诊断，并用交叉验证评估外部拟合效果。模型结果整体显著，F=14.43，$p=1.95\times10^{-11}$。BMI与年龄对Y浓度呈负相关，孕周与胎儿健康状态呈正相关。结果表明在控制年龄与胎儿健康状态后，BMI增高与孕周提前或推迟对胎儿Y浓度具有方向明确且统计显著的影响。虽然该模型解释力有限，但效果非常显著，这为后续分组与最佳检测时点研究提供了基础依据。

问题二中，针对男胎孕妇的NIPT时点优化问题，本文按多策略分组（分位数+临床标准+边缘样本合并）将孕妇分为五组，针对每组孕妇建立了Logistic达标概率模型，结合晚期风险函数构建综合损失函数，通过最小化损失确定各BMI分组的最佳检测时点。利用Monte Carlo模拟处理检测误差，并进行敏感性分析，结果表明最优检测时点在16～18周之间，置信区间波动较小，模型稳健，可为临床提供个性化检测建议。

问题三中，依旧是NIPT时点优化，但加入了更多考虑变量，针对胎儿Y染色体浓度检测，探讨了检测误差对最佳检测时点的影响。通过对孕妇样本进行BMI规则分组和聚类分组，采用Cox生存模型估计首次达标孕周的分布，并计算最佳检测时点。结果显示，规则分组揭示了BMI对检测时点的差异化影响，而聚类分组结果更集中、区间更窄，具有更好的稳定性。进一步的Bootstrap、参数级蒙特卡洛、观测噪声模拟不确定性分析表明，最佳时点结论具有鲁棒性。通过引入损失函数修正，避免了过晚检测，最佳检测时点稳定在18周左右，更符合临床早期发现的需求。

问题四中，针对女胎的异常判定，本文采用逻辑回归（L1正则）与随机森林方法，对X染色体浓度、相关Z值、BMI、年龄及测序指标进行特征筛选建模，并制定灰区样本的二次判定规则。结果显示，逻辑回归在阈值0.8、随机森林在阈值0.13时最佳，核心特征为6个变量。与传统双阈值法相比，模型在特异度≈0.99的同时显著提高灵敏度。该方法不仅提升了异常检出率，还能有效处理灰区样本，降低漏检风险，为NIPT临床应用提供更稳健依据。

本文提出稳健求解策略：男胎结合多元回归、稳健标准误与交叉验证分析Y染色体浓度，并以Logistic、Cox模型及蒙特卡洛模拟构建损失函数，推算个性化最佳检测时点；女胎利用L1正则逻辑回归与随机森林完成灰区判定与特征筛选。全程引入稳健性与不确定性分析，方法可靠，可直接指导临床个性化NIPT检测。

关键词：多元线性回归　NIPT时点优化　生存模型　灰区样本二次判定

一、 问题重述

NIPT 是一种通过采集孕妇血液中的胎儿游离 DNA 片段，分析胎儿染色体是否异常的产前筛查技术。该技术主要用于早期发现胎儿是否存在唐氏综合征（21 号染色体异常）、爱德华氏综合征（18 号染色体异常）和帕陶氏综合征（13 号染色体异常）等常见染色体疾病。NIPT 的准确性很大程度上依赖于胎儿性染色体（男胎为 XY，女胎为 XX）的浓度判断。通常，男胎 Y 染色体浓度达到或超过 4%，女胎 X 染色体浓度正常时，可认为检测结果基本准确。

孕妇的孕周、BMI（身体质量指数）、年龄等因素会影响胎儿染色体浓度的检测结果，进而影响 NIPT 的准确性和最佳检测时点的选择。早期检测（12 周以内）风险较低，中期（13－27 周）风险较高，晚期（28 周以后）风险极高。因此，合理分组并确定最佳检测时点对降低孕妇和胎儿的潜在风险至关重要。

基于附件提供的某地区孕妇 NIPT 数据（包含多次检测、测序失败等情况），提出以下四个问题：

问题 1：利用显著性较好的模型分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标之间的相关性。

问题 2：男胎孕妇的 BMI 是影响 Y 染色体浓度最早达标时间的主要因素。要求对 BMI 分组，依据孕妇的潜在风险确定每组的最佳 NIPT 时点，最后分析检测误差对这个时间的影响。

问题 3：进一步考虑体重、年龄等多种因素对男胎 Y 染色体浓度达标时间的影响，结合检测误差和达标比例，重新对男胎孕妇的 BMI 分组，根据潜在风险最小来确定每组的最佳 NIPT 时点，并分析检测误差的影响。

问题 4：针对女胎孕妇，需综合考虑 X 染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素，以及 21 号、18 号和 13 号染色体的非整倍体检测结果（AB 列），建立女胎异常的判定方法。

二、 问题分析

2.1 问题一的分析

问题一需要刻画出男胎母体 cfDNA 中 Y 浓度随孕周(GA)、BMI 等指标的变化关系，给出统计显著的关系模型并完成诊断。先对全部数据进行探索分析和可视化处理，初步观察数据的性质，决定 Y 染色体浓度的数据是否需要取对数值，观察是否呈现显著的线性关系，进而决定模型的选择。参考得到的结果选取合适的变量，此处注意是否需要交互项或分组效应。考虑回归模型（线性、非线性、多项式回归），并利用 p 值、残差分析等数值检验模型的显著性，最后通过残差、异方差诊断与敏感性分析等完成性能的评估。

2.2 问题二的分析

问题二要求对男胎孕妇的 BMI 进行分组，并在综合考虑孕妇可能存在的潜在风险与检测结果的正确性，给出各组 BMI 区间和最佳 NIPT 时点。首先提取各个孕妇 Y 染色体首次达标对应的孕周数据，分析其分布情况与数据量，对 BMI 进行合理分组。以保证各组样本数均衡且具有临床解释意义。对于检测的最优时间节点的确定，虚综合考虑在检测过早导致测序失败与检测过晚可能导致的孕妇治疗窗口期缩短的风险，构

建一个平衡这两者考量的决策优化模型，求解得到最佳 NIPT 时点。并进行误差分析，考虑潜在的检测误差及其对结果的影响，最后利用敏感性分析操作对此模型进行评估检验。

2.3 问题三的分析

问题三需要考虑母体异质性包括 BMI、年龄、身高、体重等，完成合理的分组。在多种因子和检测误差的影响下，估计胎儿 Y 染色体浓度首次达到 4%的时间分布，并据此为不同母体子群给出最佳 NIPT 检测时点，同时量化检测误差与模型参数不确定性对该时点的影响。于是模型选择生存分析和损失函数优化的结合，用生存模型估计累积达标概率函数 F(t)，同时构建损失函数 L(t)兼顾未达标风险和晚期检测的风险来求解群体最佳时点。随后用参数层蒙特卡洛、观测层扰动和 Bootstrap 对得到的最佳 NIPT 检测时间做不确定性分析与敏感性检验。

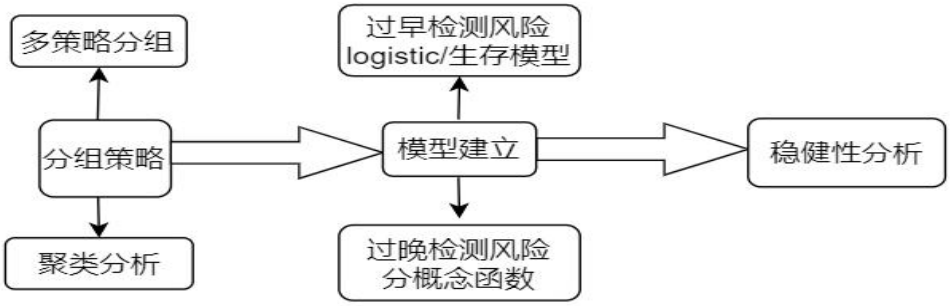

图 2-1 问题二、问题三技术路线鱼骨图

2.4 问题四的分析

问题四要求针对女胎孕妇，综合考虑 X 染色体 Z 值、GC 含量、读段数、BMI、年龄及 13、18、21 号染色体的非整倍体结果，建立异常判定方法。传统双阈值 Z 值法虽常用，但在本数据中灵敏度仅 0.091，漏检严重，且缺乏对灰区样本的处理。为改进该问题，本文在数据质控与清洗后，构建候选变量集，并通过相关性分析与 VIF 检验去除冗余，采用特征工程筛选核心变量。随后分别尝试逻辑回归（L1 正则化）和随机森林模型，前者具有良好解释性，后者能捕捉非线性特征，并针对灰区样本设计二次判定规则，以避免单纯复检带来的不确定性。

三、 模型假设

1. 假设母体状况稳定，孕妇没有自身免疫性疾病、子痫前期或癌症等疾病，母源游离 DNA 水平正常【10】。

2. 假设测序深度、GC 含量、数据质量评估标准等实验室技术稳定，得到数据结果可靠。

3. 假设实验测量误差是随机的、均值为 0、服从独立同分布，不随孕周系统性偏移。

四、 符号说明

符号	说明	单位
$R(X_i)$	变量 X 的秩	
$R(Y_j)$	变量 Y 的秩	
$p(t)$	孕周 t 时胎儿 Y 染色体浓度达到 4%的概率	
b	截距，反映孕周为 0 时的基准概率	
k	斜率，刻画浓度随孕周增加的速率	
$R(t)$	孕周 t 时因过晚检测带来的临床风险	
w	晚期风险权重系数	
σ	检测误差标准差	
t*	最佳 NIPT 时点	周
P2	2% 分位点	
Z_{max}	13、18、21 号染色体 Z 值最大值	
Z_{mean}	13、18、21 号染色体 Z 值均值	
GC_{dev}	样本 GC 含量与 0.5 的偏离程度	

五、 模型的建立与求解

5.1 数据的整理与可视化分析

本小节详细介绍对附件胎儿检测数据的处理过程。首先对原始读段数、在参考基因组上比对的比例绘制数据密度图，对重复读段的比例和唯一比对的读段数绘制箱线图，可视化胎儿测序数据的整体质量；其次对胎儿检测数据进行完整的数据清洗和标准化，用于下文的趋势分析、整体数据探索；最后对男女胎儿的孕妇怀孕次数与生产次数统计，并绘制扇形图直观展示男女胎儿样本结构性差异。

5.1.1 测序数据的质量可视化

对于 NIPT 来说，原始读段数反映了测序过程中获取的所有 DNA 片段的数量，较高的原始读段数通常意味着测序深度较高，能够提供更多的信息，有助于提高分析的准确性；在参考基因组上比对的比例反映了测序数据与已知基因组的匹配程度，较高的比对比例通常意味着测序数据的质量较高，检测结果较为可靠。重复的读段会浪费测序资源，并可能影响结果的准确性，而唯一比对的读段数则可以表示检测到的胎儿 DNA 片段是否与已知的染色体区域一致[1]。

本小节对原始读段数、在参考基因组上比对的比例绘制数据密度图，以此帮助识别样本质量差、测序深度不足等问题，并进行数据筛选。对重复读段的比例和唯一比对的读段数绘制箱线图，可以评估样本中是否有足够的唯一比对的读段来支持后续分析，避免误差。

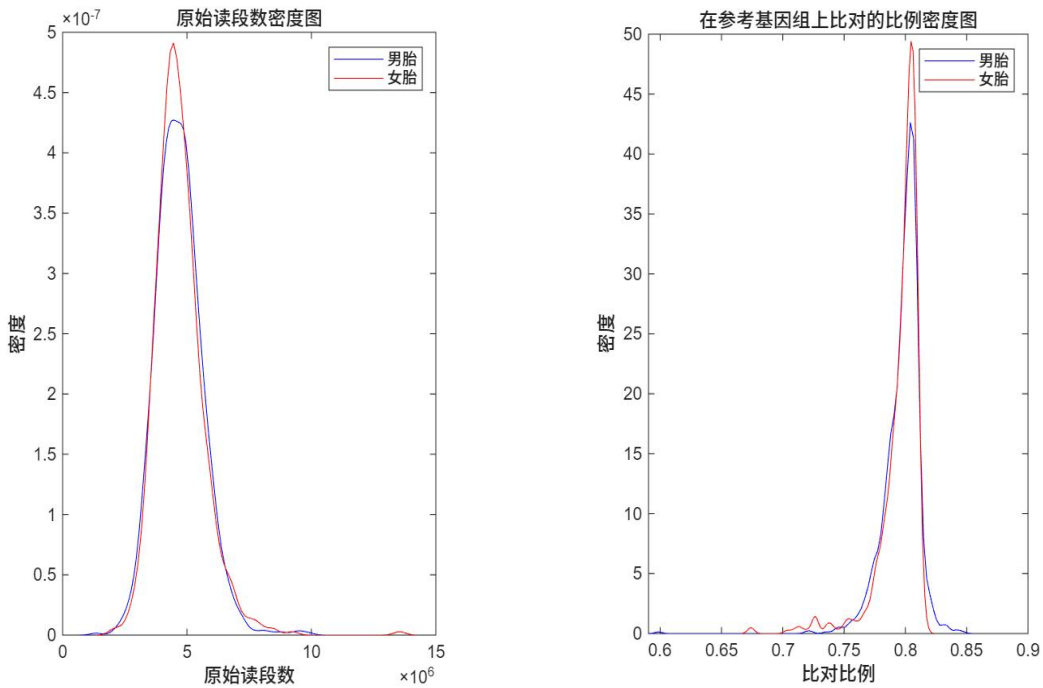

图 5-1 原始读段数、在参考基因组上比对的比例数据密度图

原始读段数密度图（左图）高密度集中于 5×10^6 至 7×10^6，男胎与女胎的测序深度和数据量差异不大，大多数样本都有良好的数据覆盖度和测序质量；在参考基因组上比对的比例密度图（右图）显示，男胎和女胎的比对比例分布几乎重合，都集中在 0.75 到 0.8 之间，表示大部分测序数据都能准确比对到参考基因组。

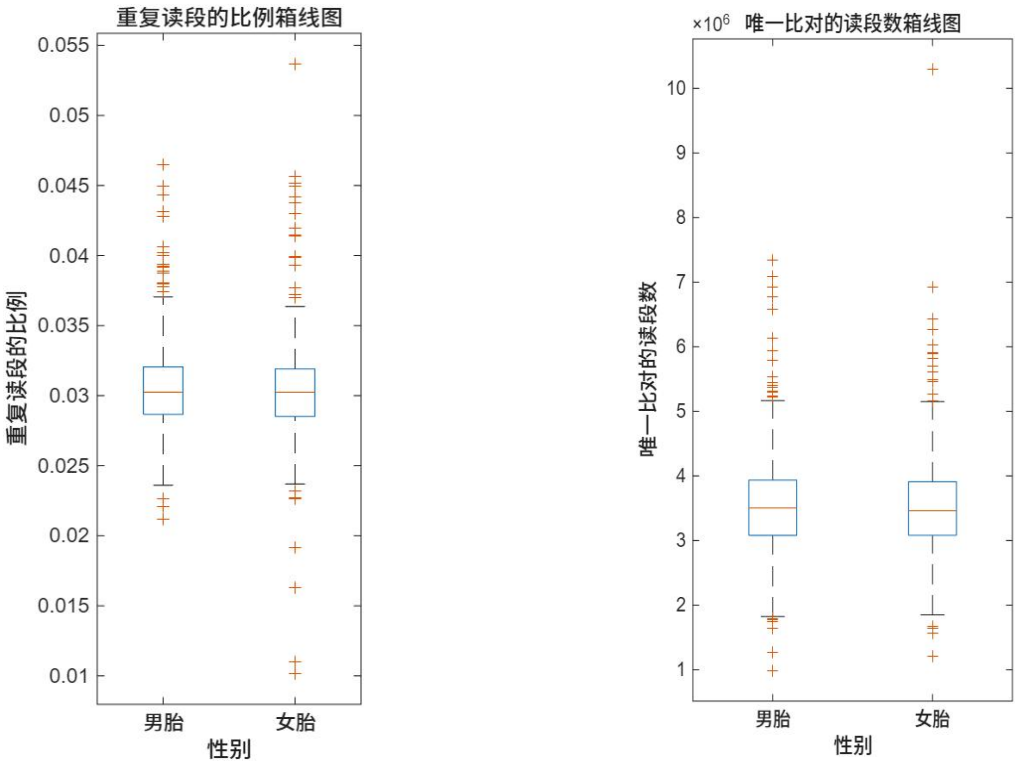

图 5-2 重复读段的比例、唯一比对的读段数箱线图

重复读段比例与唯一比对的读段数箱线图均显示，男胎和女胎的重复读段比例大

致相同，这意味着两者在样本质量方面没有显著差异，DNA 片段能够高效地与参考基因组比对。但女胎的数据中有一些明显的异常值，表示某些样本的测序质量较差或者某些区域的 DNA 重复性较高。

综上，男胎和女胎的测序质量相似，且整体测序数据质量较好。尤其是原始读段数和比对比例都表明数据有较好的覆盖度和准确性，男胎和女胎的唯一比对读段数的分布相似，表明两者的测序准确性相近。但女胎在重复读段的比例上略高，并且存在一些异常值，可能表明某些样本的测序质量较差。在进行 NIPT 分析时，对于这些异常数据应进一步清洗和筛选，以确保最终结果的准确性和可靠性。

5.1.2 数据预处理

根据以上测序数据的质量分析，对附件胎儿监测数据主要做了以下更改:

首先转化孕周为数值并且更改检测日期为标准日期格式，便于下文数据处理和对 NIPT 时点的准确判断；

其次修正 BMI，对于附件男胎检测数据，发现原 BMI 有 21 处错误，用孕妇已知身高和体重重新计算的 BMI 替代；

$$BMI = \frac{\text{体重}}{\text{身高}^2} \tag{5-1}$$

然后标记缺失样本，统计共有必填字段缺失 131 处、Y 染色体浓度缺失或异常 8 处均进行删除处理；设置阈值过滤较低原始读段、在参考基因组上比对的比例和唯一比对比例数据，其中设置原始读段数阈值为 10^6、在参考基因组上比对的比例阈值为 70%和唯一比对比例阈值为 40%共过滤 8 处。原始数据共 1082 个样本，最终可用样本剩余 929 个。

5.1.3 男女胎儿的孕妇怀孕次数与生产次数统计

NIPT 检测通常对多次怀孕的产妇非常重要，因为这些群体的胎儿可能面临更高的染色体异常风险。统计男女胎儿的孕妇怀孕次数与生产次数能够更有效地分组分析不同类型的母亲人群，通过对怀孕与生产次数的分布分析，帮助识别哪些孕妇群体可能需要进行 NIPT 筛查，进一步提供个性化的健康管理和风险评估。

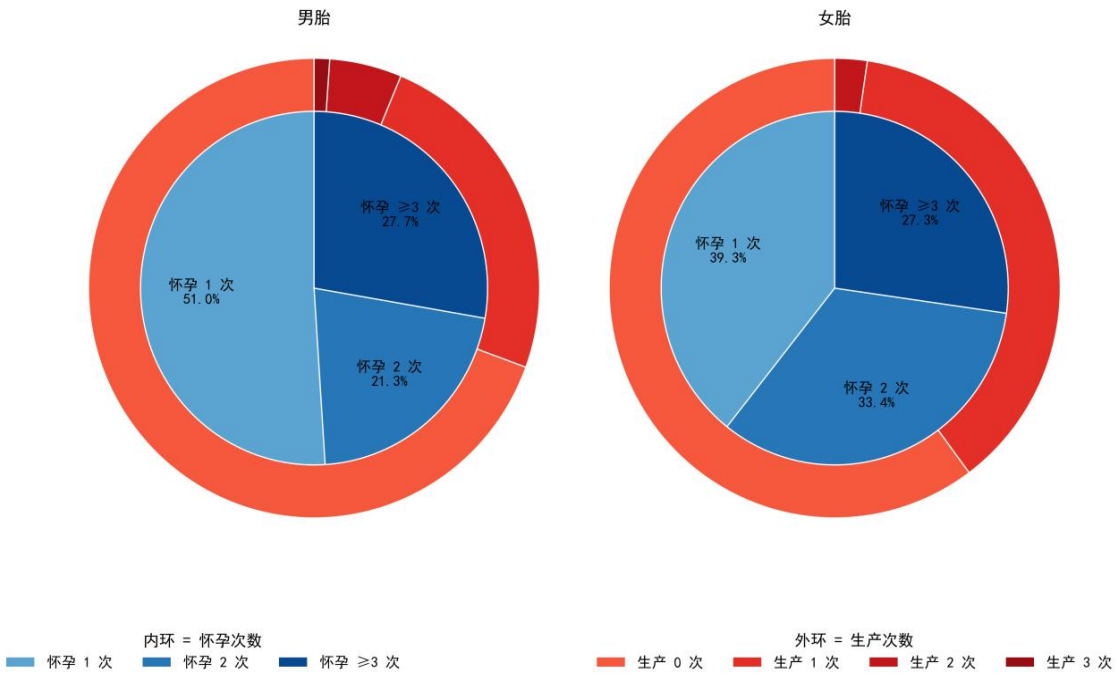

图 5-3 男女胎儿的孕妇怀孕次数与生产次数扇形统计

多层扇形图显示，样本中孕妇的怀孕次数和生产次数整体呈现集中分布，但男胎与女胎的怀孕次数和生产次数分布有所不同。对于男胎，约 51%的母亲怀孕一次，而 27.7%的母亲怀孕三次或更多；与此相比，女胎的分布略有差异，39.3%母亲怀孕一次，27.3%怀孕三次或更多。通过多层扇形图能够观察到怀孕次数与性别之间的关联，表明男胎和女胎在怀孕次数分布上的一定差异，这为后续的无创产前检测（NIPT）筛查提供了群体划分的依据。

5.2 问题一模型的建立与求解

本节需要分析胎儿 Y 染色体浓度与孕妇的孕周数和 BMI 等指标的相关特性，查找文献可知胎儿 Y 染色体浓度主要通过孕妇血液中的游离胎儿 DNA 进行检测，通常用于 NIPT 来筛查胎儿的性别及一些遗传病，结合附件胎儿检测的数据，确定 Y 染色体浓度可能与以下指标均有一定的相关性：孕妇体重、BMI、年龄、孕周和胎儿健康状况。接着对这五个自变量与 Y 染色体浓度进行探索性分析以确定变量之间的关系，从而进一步选定模型，检验其显著性。

5.2.1 数据探索与特征选择

1、可视化分析

首先使用直方图对检查胎儿 Y 染色体浓度的分布进行可视化，判断是否需要将 Y 染色体浓度进行取对处理，利用预处理后的数据绘图如下：

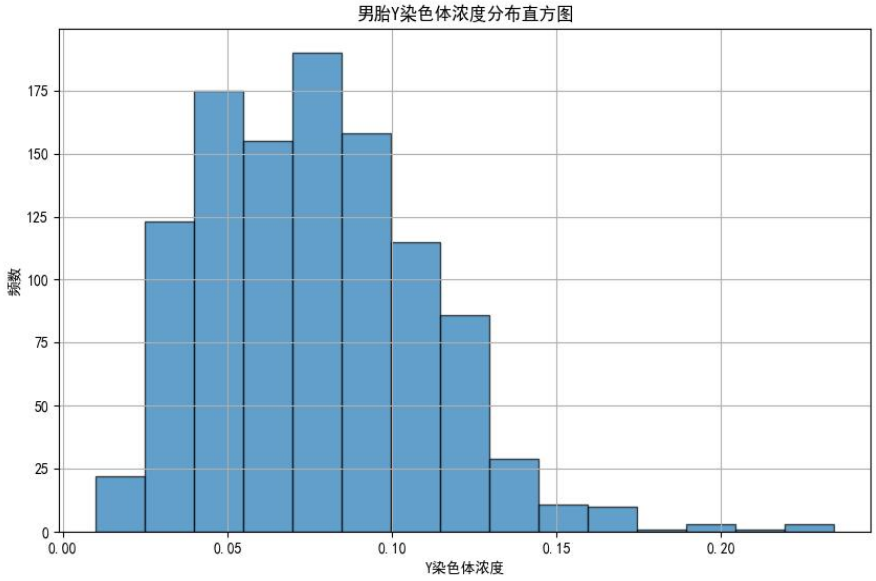

图 5-4 Y 染色体浓度分布直方图

从图 5-4 可以看到，数据在 Y 染色体浓度分布上呈现一定的峰值，并且分布趋势呈现出一种右偏的形态。在回归分析中，右偏分布可能导致模型对极大值的过度敏感，故对 Y 染色体浓度数据进行对数变换，使其线性化，进而改善回归模型的拟合度。

接下来绘制散点图来分析每个自变量（体重、BMI、孕周、年龄）与胎儿 logY 染色体浓度之间的关系、绘制箱线图胎儿健康状况与胎儿 logY 染色体浓度之间关系，据此可以初步判定自变量与因变量值之间是否具有线性相关性。

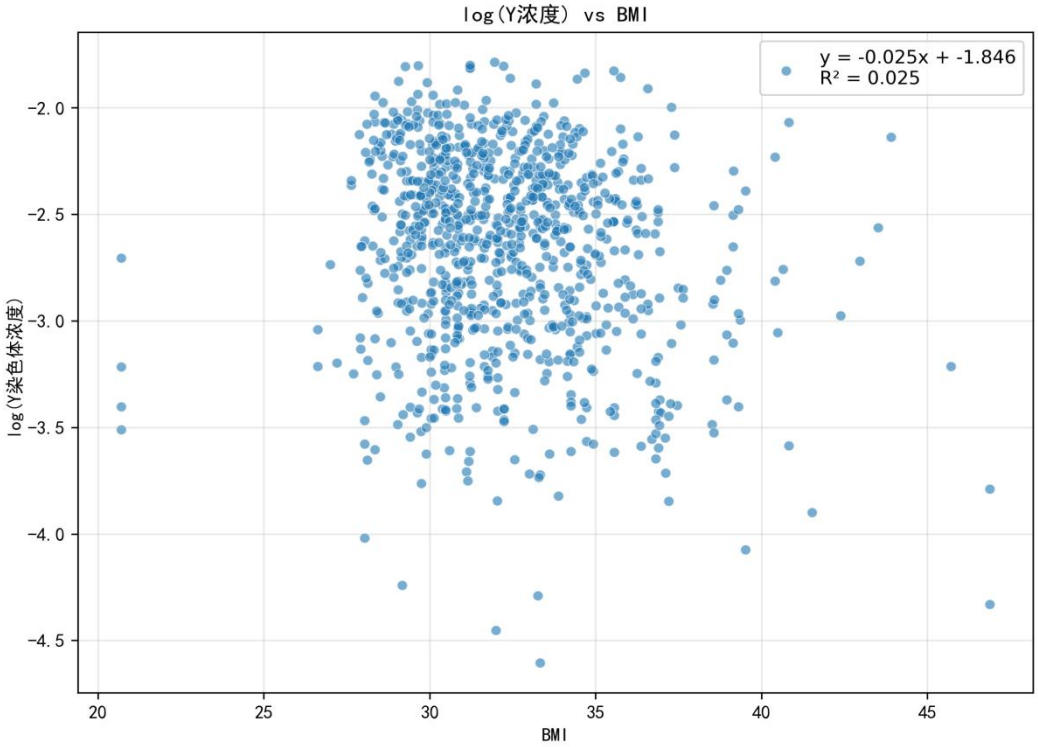

图 5-5 BMI 与 logY 染色体浓度的散点图

如上图 5-5 存在较多的波动和离群点，BMI 与 logY 染色体浓度之间的关系并不是简单线性的；同理，其他自变量与 Y 染色体浓度的散点图（附录）显示，均无明显的线性关系。

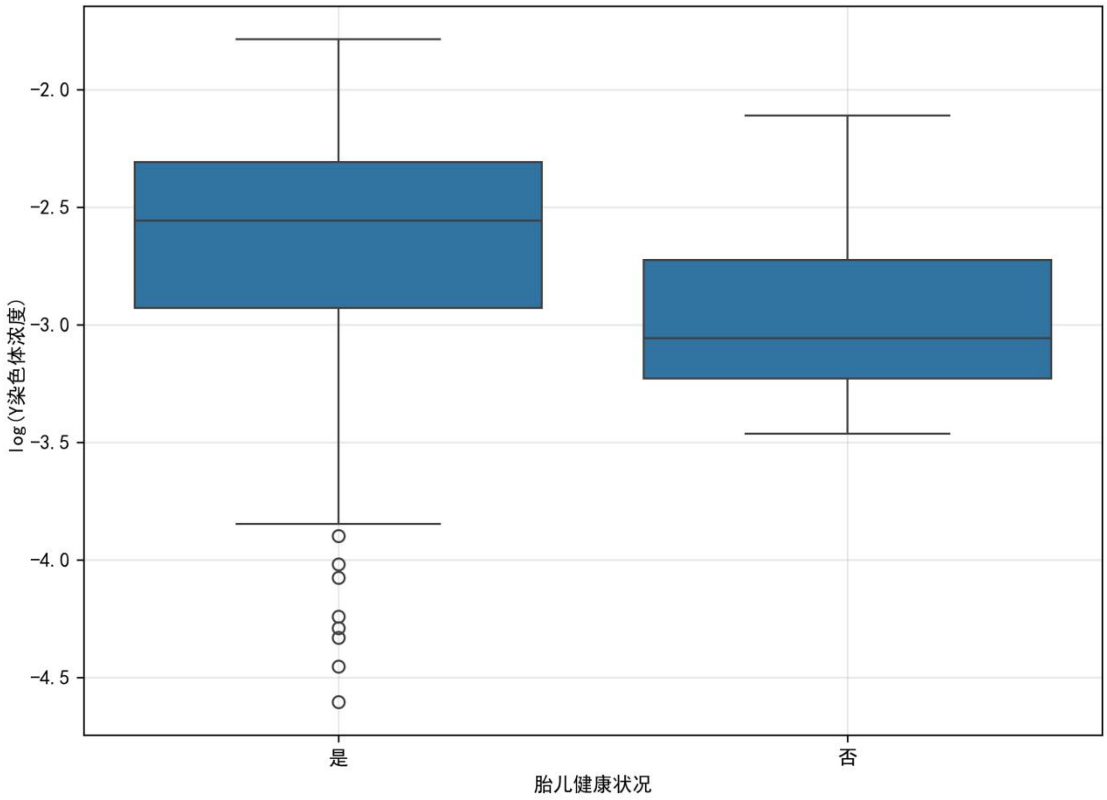

图 5-6 不同胎儿健康状况的 logY 染色体浓度箱线分布

由图 5-6 可知健康胎儿的 logY 染色体浓度中位数较高，并且四分位数范围相对集中，表示健康胎儿的 Y 染色体浓度值较为一致；不健康胎儿的 logY 染色体浓度则呈现出更大的波动，四分位数范围较宽，且有较多的离群点，这表明不健康胎儿的 logY 染色体浓度更为分散，且异常值较多。以上分析表明胎儿健康状况与 logY 染色体浓度之间存在相关性。

综上分析：

• 自变量（体重、BMI、孕周、年龄）与胎儿 logY 染色体浓度之间不未表现出明显的直接线性关系，说明在后续相关性模型的构建中需要对变量进行转换等操作。

• 健康胎儿的 Y 浓度整体更高且分布集中，不健康胎儿则分布分散并伴随更多异常值，说明胎儿健康状况与 Y 染色体浓度之间存在相关性。

2、统计性分析

（1） Spearman 相关性分析

为判断各自变量之间、自变量与胎儿 logY 染色体浓度之间关联性，使用 Spearman 相关系数计算，步骤如下：

step1 排序：将每个变量的值排序，生成每个值的秩。如果有重复值，则对重复值进行平均排名。

step2 计算秩差：

$$d_i = R(X_i) - R(Y_j) \tag{5-2}$$

step3 计算 Spearman 相关系数：

$$r_s = 1 - \frac{6\sum d_i^2}{n(n^2-1)} \tag{5-3}$$

其中 n 是数据点的总数。

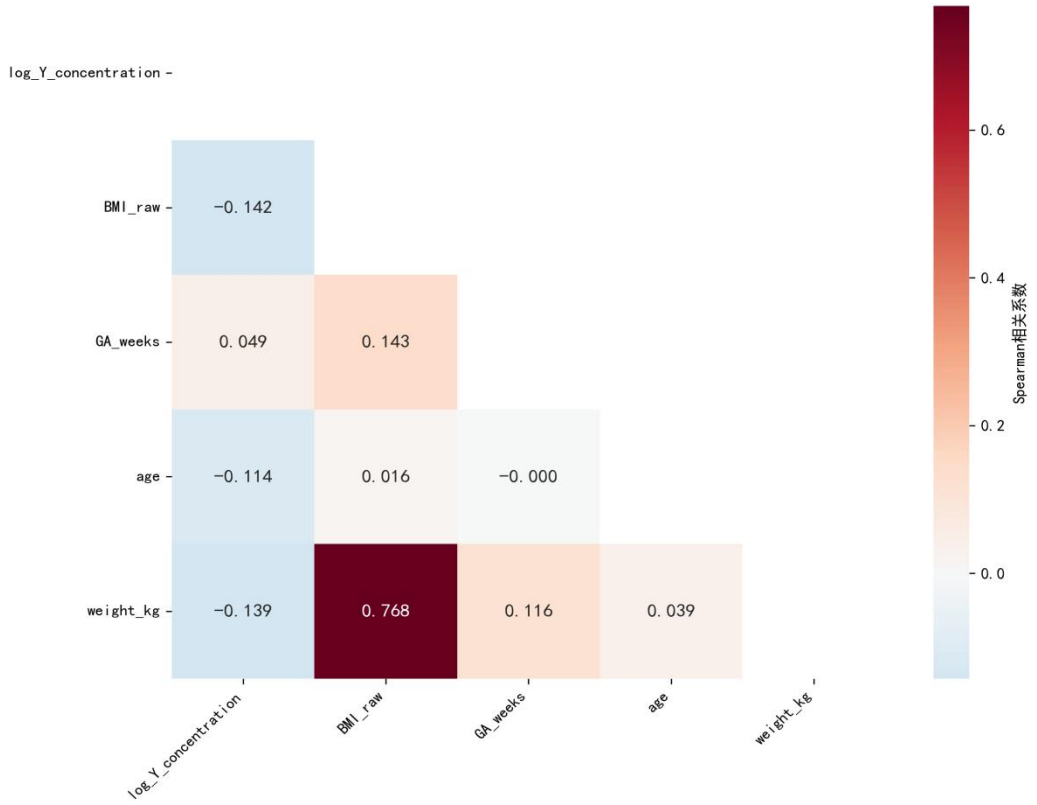

图 5-7 Spearman 相关系数热力图

由图 5-7 可知，logY 染色体浓度与 BMI、体重等因素之间呈负相关，但相关性较

弱，Spearman 相关系数绝对值均低于 0.15；BMI 和体重之间相关系数为 0.768，呈强正相关，表明体重和 BMI 之间的信息重叠较大，接下来检查各自变量之间的共线性。

（2）方差膨胀因子（VIF）

需要将每个 Xi 作为因变量，其他自变量作为自变量进行回归，其回归方程为：

$$X_i = \beta_0 + \beta_1 X_1 + \cdots + \beta_{i-1} X_{i-1} + \beta_{i+1} X_{i+1} + \cdots + \beta_n X_n + \epsilon_i$$

对每个 X_i 计算 VIF：

$$VIF(X_i) = \frac{1}{1 - R_i^2} \tag{5-4}$$

其中，R_i^2 是自变量 X_i 与其他自变量回归的决定系数；当 VIF 值大于 10 时，表示存在多重共线性。

变量	VIF
BMI（X_1）	3.255788
体重（X_2）	3.236341
孕周（X_3）	1.024465
年龄（X_4）	1.005859

表 5-1 方差膨胀因子 (VIF) 检查

表 5-1 中 VIF（X_1）≈3.26，VIF（X_2）≈3.24，表明 BMI 和体重之间确实有中等相关性（上文分析体重和 BMI 强相关），但还在可接受范围（VIF(X_i)<5），自变量之间没有严重的共线性问题。

但是因为身高差异不大，那么 BMI 和体重基本就是线性相关的。在模拟计算中发现多元线性回归分析的 Condition Number 和岭回归都显示模型矩阵存在整体数值不稳定，主要是因为 BMI 数据和体重本质上有公式上的相关性。Condition Number 是对设计矩阵整体做奇异值分解，反映整体数值稳定性。即此处出现了冗余变量和数值尺度影响导致整体数值的不稳定，考虑到 BMI 的综合性质，在此处删除冗余，减去体重这个变量，保留 BMI 值。

3、小结

综合可视化分析和统计性分析的结果，先对 Y 染色体浓度单独分析，发现右偏，于是采取对数值的计算处理。考察自变量，包括体重、BMI、孕周、年龄，与胎儿 Y 染色体浓度取对数的值的关系。发现 Y 染色体浓度的对数值与 BMI、体重、年龄因素之间呈负相关，与孕周呈现正相关。而 BMI 和体重的数据出现了冗余和数值尺度影响导致整体不稳定的现象，于是筛选出 BMI、孕周、年龄三个主要产生影响的自变量，这三个自变量结合因变量为 Y 染色体浓度对数值建立起多元线性回归模型。

5.2.2 回归模型确立与验证

多元线性回归模型（OLS），以胎儿 Y 染色体浓度的对数值为因变量，以孕妇的 BMI、年龄、孕周数、胎儿健康情况为自变量，建立以下表达式：

$$log(Y_{conc}) = \beta_0 + \beta_1 \cdot BMI + \beta_2 \cdot age + \beta_3 \cdot GA_weeks + \beta_4 \cdot fetus_healthy + \varepsilon$$

模型的建立完成后，本文此处对模型进行了系统的显著性检验与诊断。

1、模型总体显著性检验（F 检验）

零假设 H_0：所有自变量的系数均为 0；

备择假设 H_1：至少有一个自变量对因变量具有显著影响。

$$F = \frac{SSR/k}{SSE(n-k-1)} \tag{5-5}$$

回归输出中给出了 F = 14.43，对应的显著性水平 P= $1.95 \times 10^{-11} < 0.001$,由于 P 值远小于 0.05，显著拒绝零假设，说明所建回归模型整体上具有统计学意义，即自变

量对 Y 染色体浓度的变化具有解释力。

2.异方差与残差诊断

为保证回归结果的可靠性，本文进一步进行了异方差检验和残差分析：

先进行了 White 检验，得到结果 p = 0.0002 提示模型可能存在异方差，而 Breusch–Pagan 检验（p = 0.457）未发现显著异方差。考虑到 White 检验结果，本研究进一步采用 HC3 稳健标准误对回归系数进行修正，以保证显著性检验的稳健性和结果的可靠性。

下一步完成残差诊断如下图。

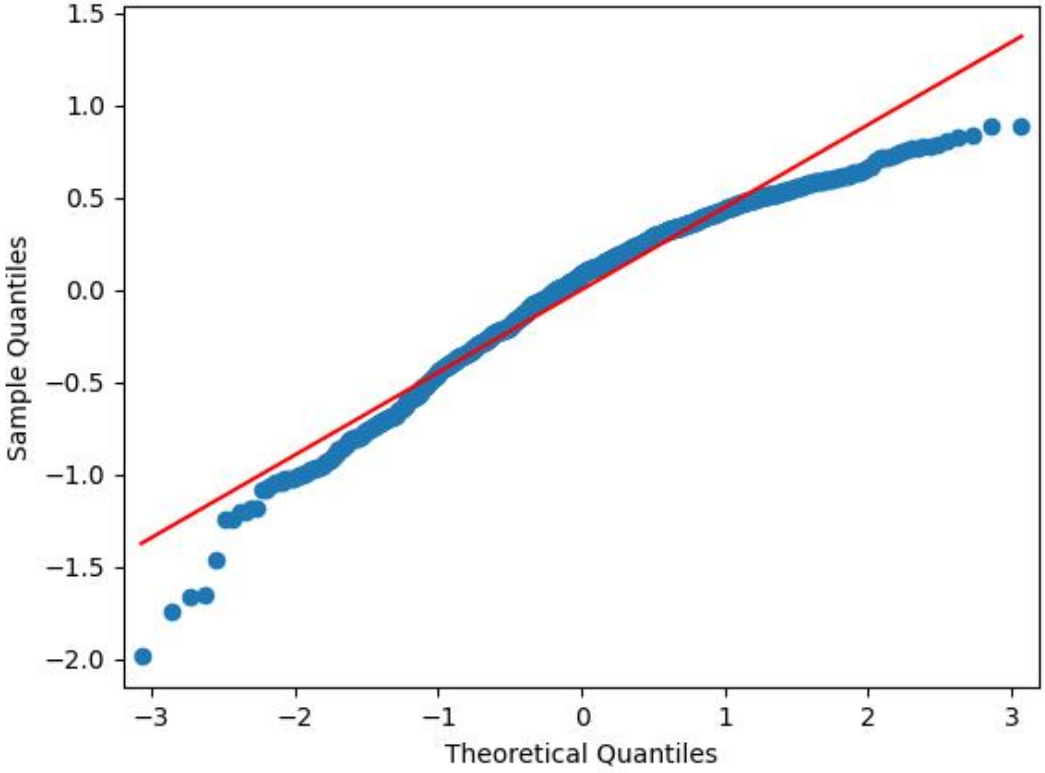

图 5-8 显示残差分布图

QQ 图显示残差分布接近正态，残差与拟合值散点图未见明显模式，说明模型线性假设基本成立[2]。

3.单个变量的显著性检验（t 检验）

由于 White 检验提示可能存在异方差性，本研究采用了 HC3 类型的异方差稳健标准误对回归系数进行修正。HC3 对标准误进行了保守估计，因此能够在有限样本下提高 t 检验和 F 检验的稳健性，保证了显著性检验结果的可靠性。在异方差稳健标准误（HC3）下，各自变量的 t 值及 p 值如下：

回归系数	回归系数值	t 值	P 值	说明
β_1	-0.0272	-4.238	p < 0.001	孕妇 BMI 对胎儿 Y 浓度有负影响，可能与母体脂肪分布、血浆容量稀释或胎盘功能有关。
β_2	-0.0093	-2.189	p = 0.026	年龄增加对 Y 浓度有轻微负向影响高龄孕妇的胎盘功能和循环环境可能更差，导致胎儿 DNA 浓度降低。
β_3	+0.0090	2.491	p = 0.016	孕周越大，Y 浓度越高，胎儿 DNA 进入母体循环的量增加

β_4	+0.2784	4.008	p = 0.001	胎儿健康与母体循环中 cfDNA 浓度存在正向关系，不健康胎儿可能因为发育迟缓、流产倾向，导致 DNA 浓度水平下降。

表 5-2 回归系数与检验说明表

综上，所有纳入的变量均在 0.05 水平下显著。

通过 F 检验和 t 检验，我们确认模型整体和各自变量均显著；采用 White 和 Breusch–Pagan 检验对异方差进行了评估，并通过稳健标准误修正保证了结果的可靠性。交叉验证进一步表明，模型能捕捉显著关系，具有一定整体解释力，为后续问题做出了很好的铺垫。

代入估计系数，得到具体模型：

$$log(Y_{conc}) = -1.9259 - 0.0272 \cdot BMI - 0.0093 \cdot age + 0.0090 \cdot GA_weeks + 0.2784 \cdot fetus_healthy$$

其中：fetus_healthy = 1 表示“是”，fetus_healthy = 0 表示“否”；误差项ε服从正态分布假设。

5.3 问题二模型的建立与求解

本节需要研究的是依据孕妇 BMI 将男胎孕妇合理分组，在综合考虑达标概率与潜在风险的情况下，找出每组孕妇的最佳检测时点并对检测误差影响进行评估。在制定分组策略时需要考虑 BMI 和首次达标时孕周（最佳检测时点）的关系，加入对潜在风险的考量，选择合适的风险函数对分组策略的合理性进行量化，得到最佳 NIPT 时点。并对检测误差导致的影响进行误差分析，最后进行敏感性分析等模型检验以评估模型的效果与稳定性。

5.3.1 数据处理和分析

根据题意规定以下判断标准：

• NIPT 准确性判定标准：一方面是孕妇的孕期需达到 10 周～25 周左右；另一方面是男胎的 Y 染色体浓度≧4%、女胎的 X 染色体浓度没有异常。

• 风险区间：早期发现（≦12 周）风险较低；中期发现（13～27 周）风险高；晚期发现（≧28 周）风险极高。

1、重复检测数据处理：在男胎检测数据中，设定达标条件为 Y 染色体浓度≧0.04，保留单个孕妇满足该条件的最早检测时间，即筛选出首次胎儿 Y 染色体浓度的最早达标时间的记录。

2、描述性统计

	BMI	首次达标时孕周	首次达标时 Y 染色体浓度
均值	32.2642	13.9971	0.0726
方差	2.9978	2.9860	0.0238
最小值	20.7031	11.0000	0.0401
25%	30.1999	12.2857	0.0521
50%	31.7266	12.9286	0.0708
75%	33.8571	13.8571	0.0884
最大值	46.8750	26.4286	0.1609

表 5-3 BMI、首次达标时孕周与 Y 染色体浓度汇总统计

表 5-3 中整体 BMI 偏高，首次达标孕周多集中在 12～14 周，提示大部分孕妇在孕早期即可达到检测标准。其中达标孕妇人群的平均 BMI 为 32.26，且四分位间距为 3.66，说明大多数孕妇的 BMI 集中在 30～34 之间，整体处于超重及肥胖范围；首次

达标时孕周的极差符合 NIPT 准确性判定标准区间。

3、数据分布可视化

本节研究的变量是 BMI、首次达标时孕周和首次达标时染色体浓度，下面更进一步研究需要刻画三者之间的关系以便制定合适的 BMI 分组策略，绘制 BMI 和首次达标孕周的散点图如下：

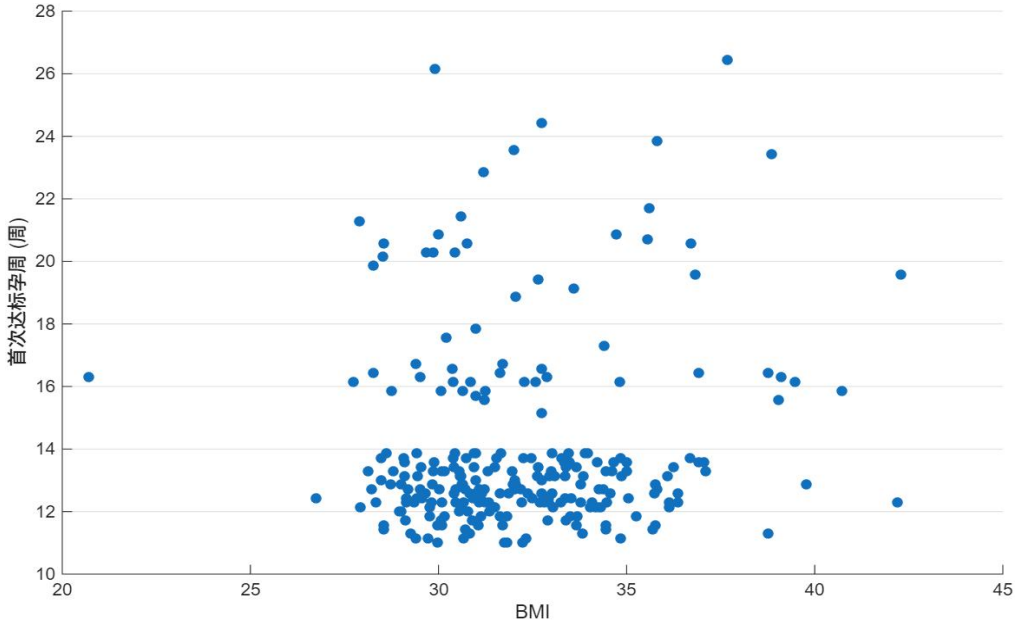

图 5-9 BMI 和首次达标孕周的散点图

图 5-9 中 BMI 范围 25～40 之间，大多数孕妇的首次达标孕周集中在 12～16 周左右，呈现一个比较密集的水平带；少部分孕妇在 18～26 周才达标，但这些点散布在整个 BMI 范围内，并没有集中在高 BMI 区域，表明整体线性关系很弱，对 BMI 和首次达标时孕周的关系研究不能依赖简单的线性分析。并且图中存在几处极端异常值，需要在原数据集中删去。

同时为了验证 Y 染色体浓度阈设置为 0.04 的合理性，绘制首次达标浓度分布直方图如下：

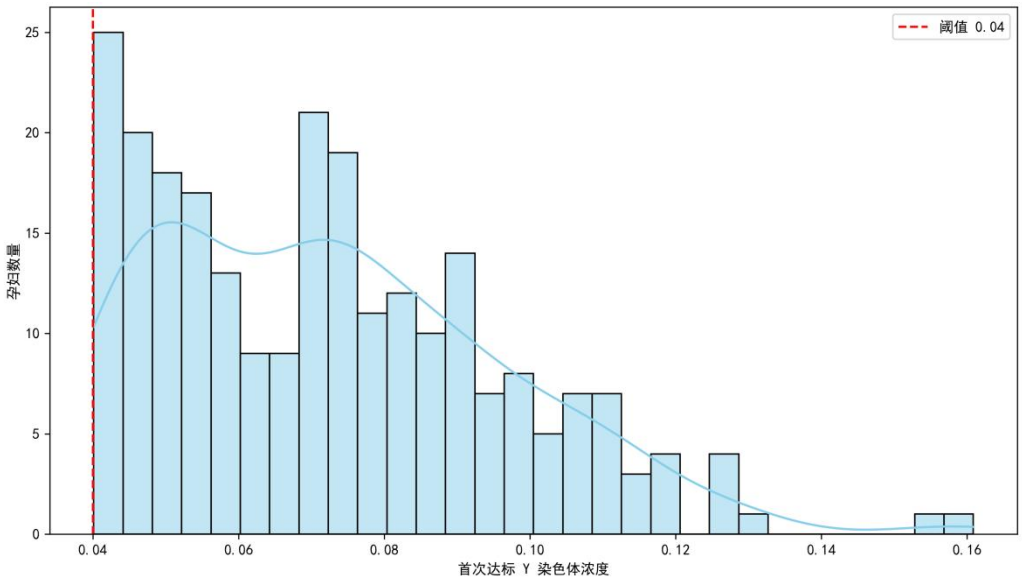

图 5-10 首次达标 Y 染色体浓度的分布情况

图中以红色虚线标记阈值 0.04 分界。结果显示，孕妇样本的 Y 染色体浓度整体分布呈右偏态，大多数浓度集中在 0.04～0.10 之间。大量临床研究报告表明，胎儿染色体浓度会随着孕妇孕周数的增大呈现上升趋势，且增速呈早期慢、中期快、后期趋于平缓的 S 型增长趋势【3】，且首次达标数据中显示首次达标 Y 染色体浓度集中在 0.04～0.10，存在部分超出阈值 0.04 的数据，与研究显示相符合。此分布情况可视化图提示设定的阈值 0.04 能够有效区分背景噪声与真实检测信号；阈值以上的样本数量显著增加，体现了 0.04 作为判定标准具有较好的合理性和稳定性。

5.3.2 分组策略制定

观察上一节数据处理和分析特点，图 5-9 散点图的 BMI 在边缘区间 20～28 和≥40 样本量少，在 28～40 样本量密集。如果采用单纯的等宽划分会导致中间分组孕妇数量过多散失分组效力，参考 WHO 的 BMI 分类标准和流行病学的研究方法，本节对孕妇 BMI 分组综合考虑按分位点【4】、临床经验与边缘合并进行划分，这样可以保证中间密集区有更精细划分且边缘少量样本不会被过度切割，让每组孕妇数更均衡。

接下来,按 10%、30%、70%、90%分位数划分 BMI，具体分组如下：BMI≦29.09、[29.10～30.55]、[30.56～33.39]、[33.40～35.82]、BMI≧35.83。

5.3.3 基于 Logistic 回归与风险函数加权的决策优化模型

对每个分组计算最佳 NIPT 时点时需要考虑：①过早风险：若太早检查有很大概率胎儿 Y 染色体浓度未达标，结果不稳定；②过晚风险：若太晚检查则会导致孕妇等待时间过长，增加焦虑与风险；为平衡这两种风险，本文采用基于 Logistic 回归与风险函数加权的决策优化模型来进行最佳 NIPT 时点的求解。

1、Logistic 达标概率函数建立

性染色体的浓度（男胎 Y 染色体浓度≥4%，女胎染色体浓度无异常）是判断 NIPT 检测结果是否准确的重要指标，大量临床与实验研究表明【5】，胎儿性染色体浓度的比例随着孕周逐渐增加，并且在妊娠早期增长缓慢、中期迅速增加、晚期逐渐趋稳，呈现典型的 S 型非线性增长趋势。已有研究指出，这种变化模式可以用 Logistic 型函数进行合理拟合，以描述孕周与达标概率之间的关系【6】。

基于上述事实，本研究设定 Logistic 达标概率函数：

$$p(t) = \frac{1}{1+\exp(-(b+kt))}, \quad t \in [8, 30] \tag{5-6}$$

其中，$p(t)$为孕周 t 时胎儿 Y 染色体浓度达到 4%的概率；参数 b 为截距，反映孕周为 0 时的基准概率；k 为斜率，刻画浓度随孕周增加的速率。通过对不同 BMI 分组孕妇的数据进行最大似然估计，可获得对应的 b 与 k 参数，从而得到各组的达标概率曲线。

在 Logistic 模型下，可进一步通过分位点计算关键孕周:50%达标孕周t_{50}与 90%达标孕周t_{90}。

选取 50%达标孕周t_{50}作为 Logistic 曲线的拐点，在该孕周时，有一半的孕妇群体达到了检测标准，即$p(t_{50}) = 0.5$，90%达标孕周t_{90}表示绝大多数孕妇群体已达到检测标准，即$p(t_{90}) = 0.9$。代入 Logistic 函数可得：

$$t_{50} = -\frac{b}{k}\ ,\quad t_{90} = \frac{-b+\ln(9)}{k} \tag{5-7}$$

通过上述公式，t_{50}与分别反映 t_{90}中位数和高百分位达标孕周，不仅提供了对不同 BMI 分组孕妇的定量比较，还可用于指导 NIPT 时点的选择。其中，t_{50}作为 Logistic 曲线的拐点，具有特殊的临床意义，代表了胎儿 Y 染色体浓度从较低到较高的重要过渡时刻，能够帮助临床明确最佳 NIPT 时点。

2、晚期风险函数的设定

将最佳检测时点设置的较为靠后可提升达标概率，但同时也会面临确诊后治疗窗口期缩短与失去干预机会等严重风险，其中早期发现（12 周以内）风险较低；中期发现（13－27 周）风险高；晚期发现（28 周以后）风险极高。因此，需要在模型中引入 随孕周增加而递增的风险函数。本小节采用分段线性函数来刻画风险：

$$R(t)=\begin{cases}0, & t\le 12,\\ \dfrac{t-12}{27-12}, & 12<t\le 27,\\ 1, & t>27.\end{cases} \tag{5-8}$$

3、综合损失函数与最优检测时点

为了平衡“检测成功率不足”与“推迟风险过大”之间的矛盾，本研究建立综合损失函数：

$$L(t)=(1-p(t))+w\cdot R(t) \tag{5-9}$$

其中：

(1-p(t))表示在孕周 t 时检测未达标的概率，即“检测失败风险”；R(t)表示在孕周 t 时因过晚检测带来的临床风险；w为晚期风险权重系数，用于衡量临床对“过晚风险”的重视程度。

通过最小化损失函数，找到两种风险的平衡点，即最优检测时点：

$$t^*=\arg\min_{t\in[8,30]} L(t) \tag{5-10}$$

4、检测误差对结果的影响

由于受测序技术、样本质量、环境因素等影响，检测值会存在一定的波动。在实际临床检测中，胎儿 Y 染色体浓度的测定并非完全精确。为此，本研究在模型中引入随机误差，假设实际观测到的浓度$\hat{Y}$可表示为：

$$\hat{Y}(t)=Y(t)+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2) \tag{5-11}$$

其中，Y(t)为理论浓度，ε为均值为 0、方差为 1 的高斯噪声，σ^2反映检测误差水平。在此基础上，采用 Monte Carlo 模拟的方法对每个孕周重复生成大量模拟样本，计算相应的达标概率 p(t)，并重新求解最优检测时点[9]：

$$t^*_{\text{sim}}=\arg\min_{t\in[8,30]} L(t;\hat{Y}(t)) \tag{5-12}$$

通过重复模拟，即可获得t^*的分布情况，以此估计最优检测时点的置信区间。通过分析在给定的合理误差范围内最优时点t^*的波动幅度大小，可以分析出模型的稳健性情况，波动越小，模型具有的稳健性较为良好。

5、敏感性分析

在求解最佳 NIPT 时点时，模型中存在两个关键参数：晚期风险权重w与检测误差标准差σ。两个参数分别反映了临床对“过晚检测风险”的重视程度与检测过程中技术噪声的大小。为评估这两个参数对最佳 NIPT 时点求解的影响，本小节对此展开了单因素敏感性分析。

敏感性分析原理：

模型中最优检测时点t^*可表示为损失函数最小化的结果

$$t^*=\arg\min_{t}[L(t;b,k,w,\sigma)] \tag{5-13}$$

其中损失函数$L(t;b,k,w,\sigma)$由两部分构成：

$$L(t;b,k,w,\sigma)=\underbrace{1-\underbrace{p_{\text{logistic}}(t)}_{\text{未达标风险}}}+w\cdot\underbrace{R(t)}_{\text{晚期风险}} \tag{5-14}$$

并通过在孕周上加入高斯随机扰动$t \sim \mathcal{N}(t, \sigma^2)$来模拟检测误差对损失函数的影响。

5.3.4 模型的求解

1、算法说明

为确定最佳 NIPT 检测时点，本小节设计了基于 Logistic 回归与风险函数加权的决策优化模型的求解算法。

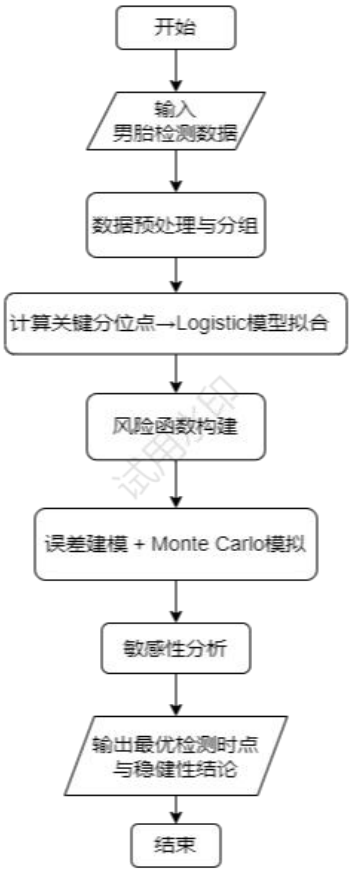

首先，对附件中的原始数据进行预处理，剔除异常值并对孕周刻度进行统一化处理，构建“是否达到检测阈值”的二分类指标。

在此基础上，采用 Logistic 回归模型刻画胎儿 Y 染色体浓度随孕周的动态变化，并通过极大似然估计方法并从拟合的 Logistic 达标概率函数中获取各组参数 b 与 k。

随后，引入风险函数以平衡检测过早导致失败与检测过晚延误临床决策，通过构建损失函数综合考量两种风险值，在数据孕周范围内损失函数最小值进行离散搜索，求得最佳 NIPT 时点 t^*。

通过 Monte Carlo 模拟引入检测误差σ，重复采样计算t^*多次，估计其 95%置信区间。

最后，通过对风险权重w和误差水平σ分别进行多次调整，分析最优检测时点t^*对这两个关键参数的敏感性。

• 算法复杂度与收敛说明

算法首先对每组数据进行 Logistic 回归拟合胎儿 Y 染色体浓度随孕周的变化，并通过离散搜索损失函数求取最佳 NIPT 时点，同时利用 Monte Carlo 模拟估计检测误差对最优时点的置信区间。此方法的计算复杂度随组数、样本量及搜索步长线性增加，MLE 拟合与多次采样为参数估计和最优时点的收敛性与稳健性提供了保证。

2、最佳 NIPT 时点求解结果

根据前述建立的基于 Logistic 回归与风险函数加权的决策优化模型，本小节针对不同 BMI 分组计算了各孕妇群体的最佳 NIPT 检测时点。通过在孕周范围 8～30 周内搜索损失函数最小值，得到各组的中位数最优时点t^*，以及对应的 50%和 90%达标孕周。结果如下表所示：

BMI 组	t_50%（周）	t_90% 达标（周）	损失最优 t*（周）
≤29.09	15.00	19.99	18.4
29.10～30.55	13.49	18.60	16.8
30.56～33.39	12.93	18.29	16.2
33.40～35.82	12.82	18.45	16.1
≥35.83	13.71	19.99	16.7

表 5-4 最佳 NIPT 检测时间表

最终选取的最佳 NIPT 时点：

• 综合达标概率与晚期风险后得到的最佳 NIPT 时点略晚于 50%达标孕周，接近 90%达标孕周，保证大多数孕妇的胎儿浓度已经达标，同时降低过晚检测带来的风险；

• 随 BMI 增加，最优时点呈轻微下降趋势，表明对于高 BMI 孕妇人群，适当将检测时间提前可以有助于降低晚期风险

3、检测误差处理与 Monte Carlo 模拟

在 Monte Carlo 模拟下，各 BMI 分组的最佳 NIPT 时点的 95%置信区间如下：

BMI ≤29.09：17.20 – 19.80 周

BMI 29.10 – 30.55：15.80 – 18.00 周

BMI 30.56 – 33.39：15.20 – 17.55 周

BMI 33.40 – 35.82：14.95 – 17.25 周

BMI ≥35.83：15.55 – 17.90 周

结果显示不同 BMI 分组的最佳时点置信区间宽度在 2.0 周左右（低 BMI 组略大，高 BMI 组略小），总体变化幅度相对孕期范围（8 – 30 周）较小，表明此模型在进行最佳 NIPT 时点计算时受误差的影响较小，具有良好的稳健性。

对于 BMI 分组、最佳 NIPT 时点与误差分析所得结果经整合后进行可视化呈现，见图 5-11（此处仅展示前两个 BMI 分组求解结果情况，其余分组见附录）。

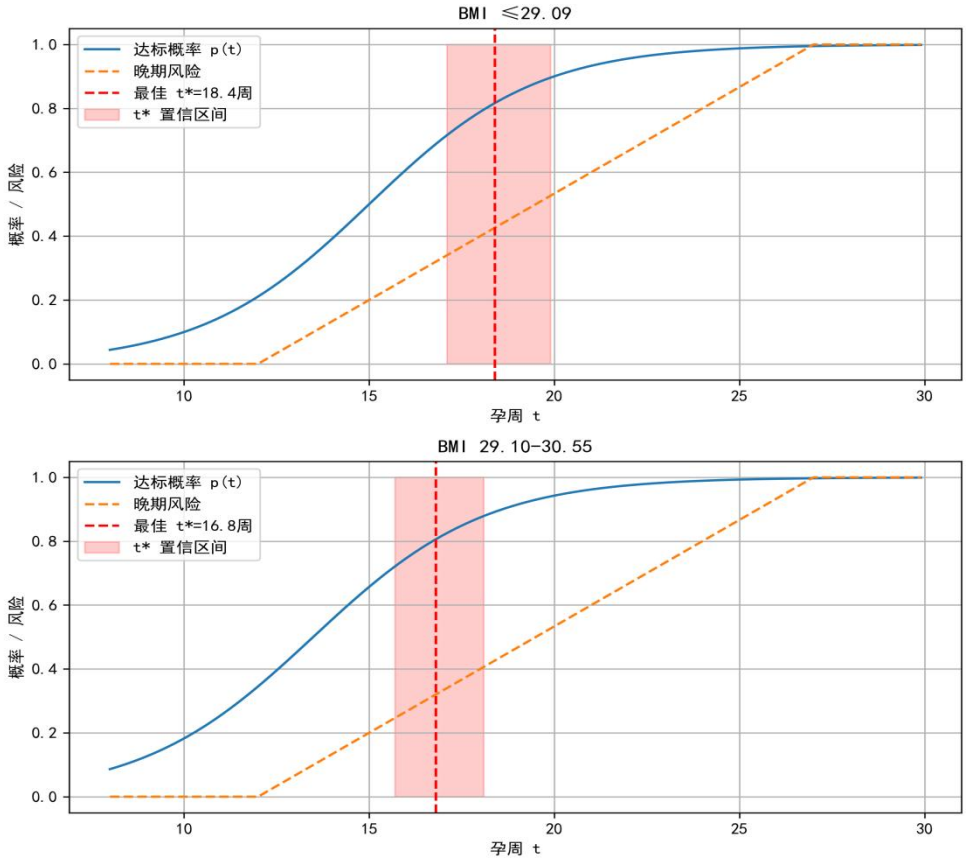

图 5-11 最佳 NIPT 时点与置信区间可视化（部分 BMI 区间）

5.3.5 模型的验证

（1）晚期风险权重敏感性分析

通过设置$w = 0.5, 1.0, 2.0$并保持检测误差σ不变，得到各 BMI 组最优时点随权重变化的情况（见图 5-12）

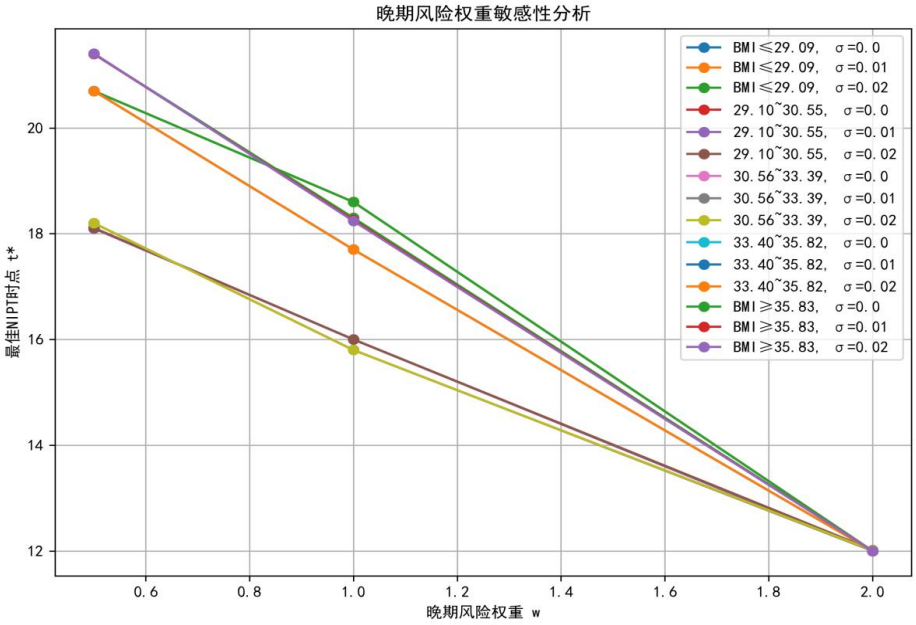

图 5-12 晚期风险权重敏感性分析

由敏感性分析可视化图可直接观察发现所有分组的最佳 NIPT 时点t^*随晚期风险权重增大而单调递减（曲线呈下降趋势）。这说明：

• 晚期风险权重w对最佳 NIPT 时点t^*的选择呈现出强敏感性。当临床对“晚期发现异常的风险”越重视（w越大），越需要对 NIPT 检测时间进行推前。

• 各 BMI 组的下降速率存在差异性：BMI 越高的组（如 BMI≥35.83），在相同 w 变化下，t^*下降更明显。这体现了高 BMI 孕妇因胎儿 Y 染色体浓度达标更晚，对晚期风险的“时间敏感性”更强，为避免晚期发现导致孕妇治疗窗口期被缩短的风险过大，需更早检测。

（2）检测误差敏感性

通过固定值w并设置检测误差$\sigma = 0.0, 0.01, 0.02$，评估最优检测时点对测量噪声的响应（见图）。

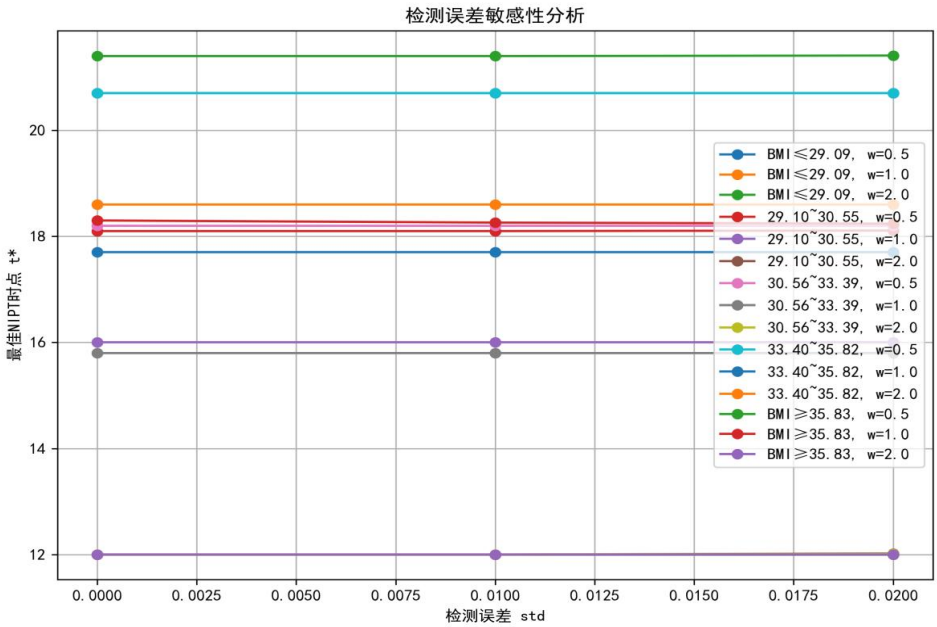

图 5-13 检测误差敏感性分析

观察上图可发现所有分组的最佳 NIPT 时点均不随检测误差变化而变化（图中呈现为水平直线）。这说明：

•检测误差对最佳 NIPT 时点的选择极度不敏感。即无论检测过程中误差如何波动，各 BMI 组在对应晚期风险权重下的最佳检测时间均是稳定的。

• 这一结果体现了本小节中构建的基于 Logistic 回归与风险函数加权的决策优化模型在检测误差维度具有良好的鲁棒性，也表明了在临床实践中无需因检测误差的不确定性大幅调整 NIPT 检测时间。

5.4 问题三模型的建立与求解

本节要求综合考虑孕妇多因素（BMI、身高、体重、年龄、孕产史）以及检测误差，来确定不同群组最佳的 NIPT 检测时点。NIPT 的关键指标是男胎 Y 染色体浓度是否达到 4%，因此本文此处着重考虑如何合理分组孕妇群体；如何建模 Y 染色体浓度达标孕周的分布；如何在存在检测误差时，依然能稳定估计最佳检测时点。

针对这些需求，在统一规则分组和聚类分组中择优，构建多因子生存分析模型，将测量误差与检测失败纳入不确定性分析，通过代价函数最小化确定每个 BMI 组的最佳 NIPT 时点t^*，并用蒙特卡洛和 Bootstrap 量化t^*的不确定性与稳健性。

5.4.1 数据的处理与分组

与问题二处理的数据方法相同，保留男胎孕妇的数据，除了首次达标时的 Y 染色体浓度等第二问已经用到的变量。问题三多提取出了相应的身高、体重、年龄、怀孕次数和生产次数等数据并清洗格式。核心目标变量仍是首次 Y 染色体浓度≥4%的孕周，剔除缺失值，完成标准化，确保 Cox 和 AFT 模型可直接使用。

为兼顾临床可解释性与数据驱动模式，又因为相比较问题二，增加了很多其他协变量，K-means 算法能高效地将样本划分为特征相似的群体，无需先验标签，适合本问题中探索性分组的需求，所以论文此处添加聚类分组方法与规则分组进行对比选取：

①统一分组（规则分组）：按照 BMI 分区，用医学经验的分组方式，和问题二的分组相同；

②聚类分组：通过“肘部法则”并结合临床解释性，确定最佳聚类数 k=3。基于 BMI、体重、身高划分潜在亚群，最终将全体孕妇划分为三个具有显著特征差异的群体（记为 K0, K1, K2 组）：

$$\begin{aligned} &\text{Minimize } J = \sum_{i=1}^{n}\sum_{j=1}^{k} r_{ij}\|\mathbf{X}_i - \mu_j\|^2 \\ &\text{where } r_{ij} = \begin{cases} 1 & \text{if } \mathbf{X}_i \in \text{cluster } j \\ 0 & \text{otherwise} \end{cases} \end{aligned} \tag{5-15}$$

得到聚类分组人数分别为：K0，113 人；K1，74 人；K2，59 人。并绘制出聚类 PCA 散点图如下，

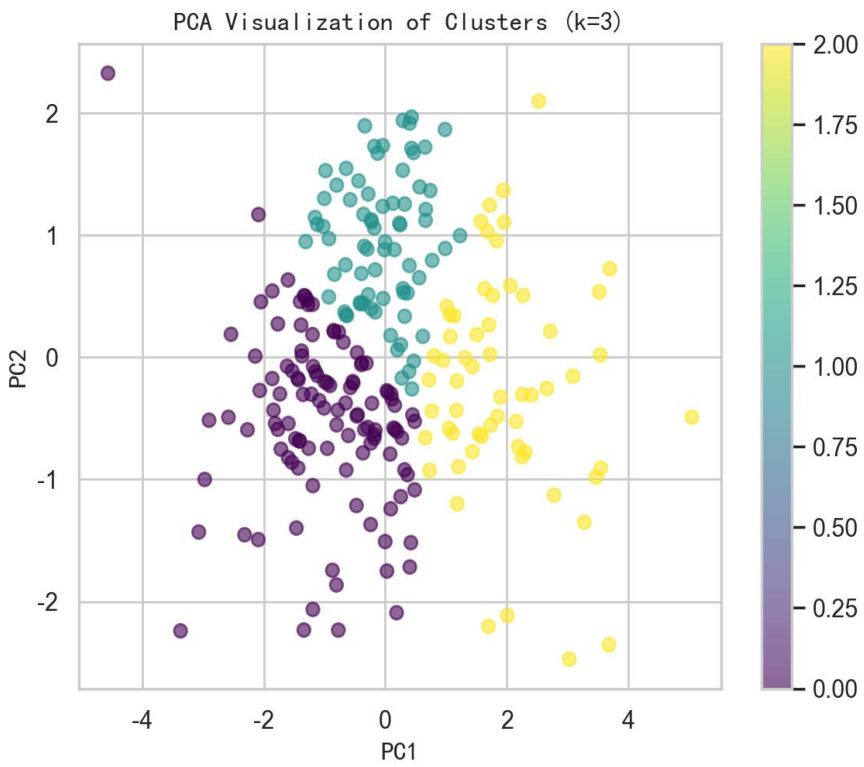

图 5-14 聚类 PCA 散点图

可以看到，组内人数差距较小，每一个点代表一名孕妇，点的颜色代表她所属的聚类分组。不同颜色的点形成了清晰的、分离的簇，形成了三个不同的聚集区域。表明分组效果良好，为后续的差异化分析奠定了坚实基础。

5.4.2 生存分析模型的建立和求解

为了确定孕妇在不同孕周首次达到 Y 染色体浓度阈值的概率，本文采用生存分析方法可处理部分孕妇未达标（删失数据）的情况，将事件指标确定为“胎儿 Y 染色体浓度是否达标”，生存条件则是其首次达到 4%的时间T_i：

$$T_i = min\{t : Y_i(t) \geq 0.04\} \tag{5-16}$$

1.生存模型的选择与建立

为拟合 Y 染色体浓度达标时间，我们为每个聚类分组分别建立了两种生存分析模型：Cox 比例风险模型和 Weibull AFT 模型，来预测达标时间分布。

• Cox 比例风险模型：

$$h(t \mid X) = h_0(t)\exp(\beta^\top X) \tag{5-17}$$

其中，$h(t|X)$为条件风险率，X 为 BMI、年龄等协变量，β为回归系数。时间 t 仍未达标的概率为基于生存模型输出的生存函数$\hat{S}(t \mid X)$，累积达标概率为$\hat{F}(t \mid X) = 1 - \hat{S}(t \mid X)$。该模型不指定基准风险函数$h_0(t)$的具体形式，灵活性高，主要用于分析各协变量 X 对达标“风险”的影响方向与强度，最后输出风险比(HR)，非常适合本问题中探索多因素影响的需求。

• Weibull 加速失效时间模型（AFT）：

$$logT_i = \eta^\top X_i + \varepsilon_i, \quad \varepsilon \sim F \tag{5-18}$$

该模型用于稳健性对比，直接对生存时间 T 进行建模，系数可解释为协变量对达

标时间的直接影响，更直观，最后输出时间比(TR)，其参数化特性使得预测结果通常比 Cox 模型更稳定，为最佳时点提供更可靠的估计。

2.最优检测时点的求解

基于累计分布函数$F(t)$（t_{50}：使$F(t)=0.5$的孕周；t_{90}：使$F(t)=0.9$的孕周；t^*：当$F(t)\geq 0.95$时的最早孕周），为避免推荐时间过晚，本文定义了综合损失函数来量化不同检测时点的总风险，并以此寻找最优解：

$$L(t)=(1-F(t))+w\cdot late_risk(t) \tag{5-19}$$

其中，

$late_risk(t)$：晚期检测的风险，随着孕周 t 增加而增大。0 < t ≤12：早期风险较低；12 < t < 27：中期风险高；t ≥ 28：晚期风险极高。

w：对晚期检测风险的重视程度的权重。这个权重可以调节早期发现的优先级与晚期风险的权重。

最后实现优化求解，对每个分组，在$t\in[8,30]$周的范围内，以 0.1 周为步长进行网格搜索，找到使损失函数$L(t)$取得最小值的点t^*，即为该组推荐的最佳检测时点t^*：

$$t^*=\arg\min_{t\in[8,30]} L(t) \tag{5-20}$$

3.模型结果与分析

在每个分组上都拟合了 CoxPH 和 Weibull AFT 两类模型后，得到不同分组的生存函数 S(t)，进一步计算t_{50}（50% 达标时间）、t_{90}（90% 达标时间）、t^*（首次达到 95% 阈值的孕周）。对每个分组拟合的 Cox 比例风险模型输出 Cox 一致性指数（concordance index） 介于约 0.55–0.72，整体反映模型对首次达标时间的排序能力较好，高 BMI 和 K2 聚类子群 C-index 相较中低 BMI 组合的 C-index 更高，即协变量与达标时间的关联更强。

分组方式	分组标签	样本量(n)	Cox 一致性指数	t_{50}(周)	t_{90}(周)	t^*(95%阈值，周)	Bootstrap 95% CI
规则分组	≤29.09	25	0.64	8.0	8.0	8.0	(8.0，20.6)
	29.10－30.55	49	0.60	8.0	8.0	26.2	(8.0，26.2)
	30.56－33.39	97	0.55	24.5	24.5	24.5	(8.0，24.5)
	33.40－35.82	51	0.64	26.5	26.5	8.0	(8.0，23.9)
	≥35.83	24	0.72	26.2	26.2	26.5	(8.0，26.5)
聚类分组	K0	113	0.58	21.8	21.8	21.8	(8.0，21.8)
	K1	74	0.58	26.2	26.2	26.2	(8.0，26.2)
	K2	59	0.67	26.5	26.5	26.5	(8.0，26.5)

表 5-5 Cox 处理结果展示表

Cox 模型结果显示，BMI≤29.09 组和 33.40–35.82 组最佳检测时点过早（8 周），说明模型在极端小样本下可能偏向过度提前，Cox 模型对这些组事件分布敏感。其他组则集中在 21–27 周之间，符合预期。并且聚类组的结果比规则分组更集中，不确定性更低，规则分组在极端值组上波动较大。

鉴于 Cox 的效果，本文接下来采取不同模型为各分组预测的达标时间分位数及通过损失函数优化得到的最佳时点如下，

分组		Cox t^*	Loss 调整 t^*	AFT t^*
规则分组	BMI ≤29.09	8.0	8.0	17.6
	BMI 29.10－30.55	26.2	12.0	20.4
	BMI 30.56－33.39	24.5	12.0	17.9
	BMI 33.40－35.82	8.0	8.0	17.7
	BMI ≥35.83	26.5	8.0	17.0
聚类分组	Cluster 0（K0）	21.8	12.0	18.5
	Cluster 1（K1）	26.2	12.0	19.9
	Cluster 2（K2）	26.5	12.0	19.4

表 5-6 最优 NIPT 检测时间表

结果表明，AFT 模型的预测值（t_{90}在 17.0-20.4 周）比 Cox 模型（部分t_{90}>26 周）更稳健且避免了极端现象。Loss 损失函数修正下所有分组的t^*基本落在 12 周左右，说明加入晚期风险权重后，算法倾向推荐更早的检测时点，以降低延迟检测的风险。综合损失函数后，本文最终推荐 K0 组孕妇在 18.0 周、K1 和 K2 组孕妇在 19.5 周左右进行 NIPT 检测，可在保证较高达标概率的同时，有效控制晚期检测带来的医疗风险。

在这个基础上，本文对每个分组都绘制了生存曲线图，曲线下降越快，就越早达标，曲线下降平缓，则需要更晚孕周才累计达到相同达标率。以 K1 为例，Cox 和 Weibull AFT 的生存曲线绘制如下，

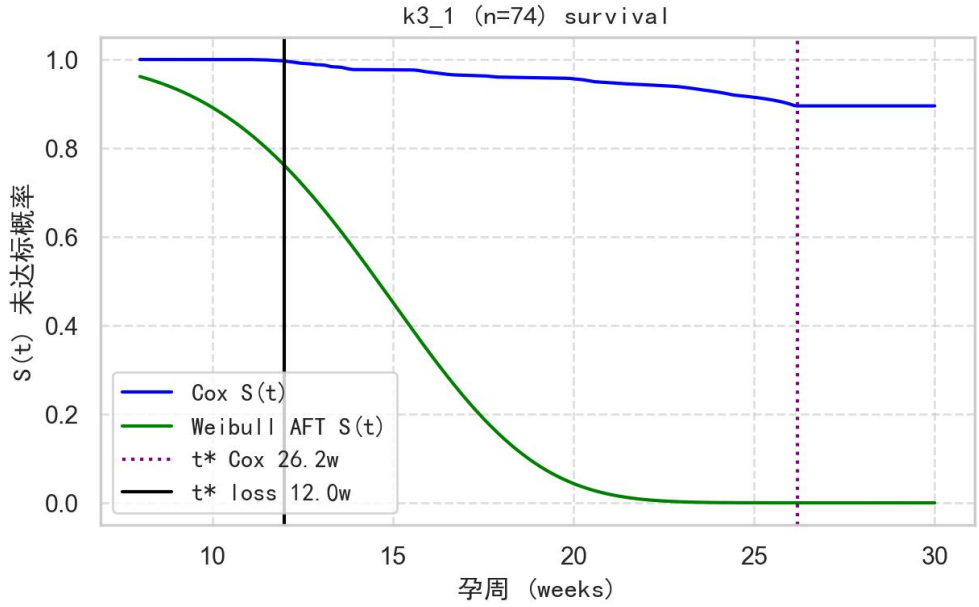

图 5-16 生存曲线图

结果显示，在规则 BMI 分组下，Cox 模型均能收敛，且随 BMI 升高，孕妇达标孕周出现一定延迟；在 K=3 的聚类分组下，不同亚群的最佳检测时点集中在 21–24 周之间，结果更加稳定。两者相比之下，规则分组具有较强的解释性，而聚类分组能够揭示潜在亚群差异。

5.4.3 检测误差与不确定性分析

为评估模型推荐结果的稳健性和可靠性，本节进行了全面的不确定性分析与误差

评估。采用蒙特卡洛（Monte Carlo）模拟方法来量化模型参数估计的不确定性如何传递至推荐时点，分为三种。

1.参数层面 Monte Carlo 模拟。在 Cox 模型参数的协方差矩阵上进行多次抽样，生成一系列可能的参数组合，从而得到不同条件下的最佳检测时点分布；

2.观测层面 Monte Carlo 模拟。在原始孕周数据上人为加入±1 周的噪声，模拟检测误差对结果的影响，评估检测误差对推荐最佳检测时间t^*的敏感性；

3.Bootstrap 重采样。重复抽样孕妇 ID，对 Cox 回归系数进行重复模型拟合，得到 t^*的分布及其 95%置信区间，以估计由样本变动引入的不确定性，区间窄，则表明我们的推荐具有较高的统计稳定性。

此处绘制蒙特卡洛模拟得到的聚类分组各组t^*值的分布直方图，并标注其均值和 95%置信区间，

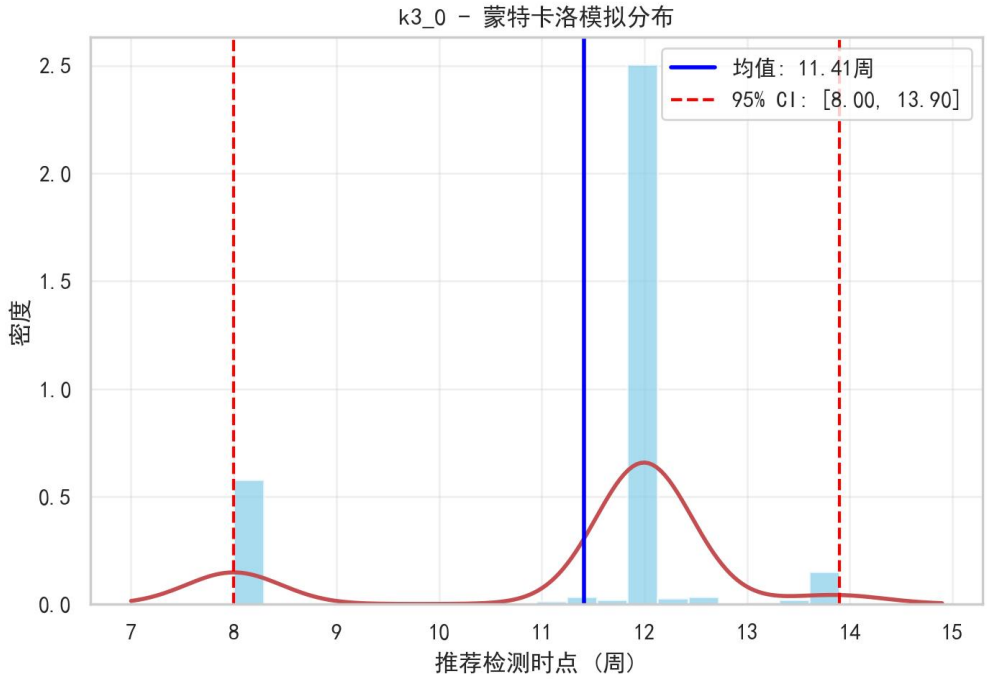

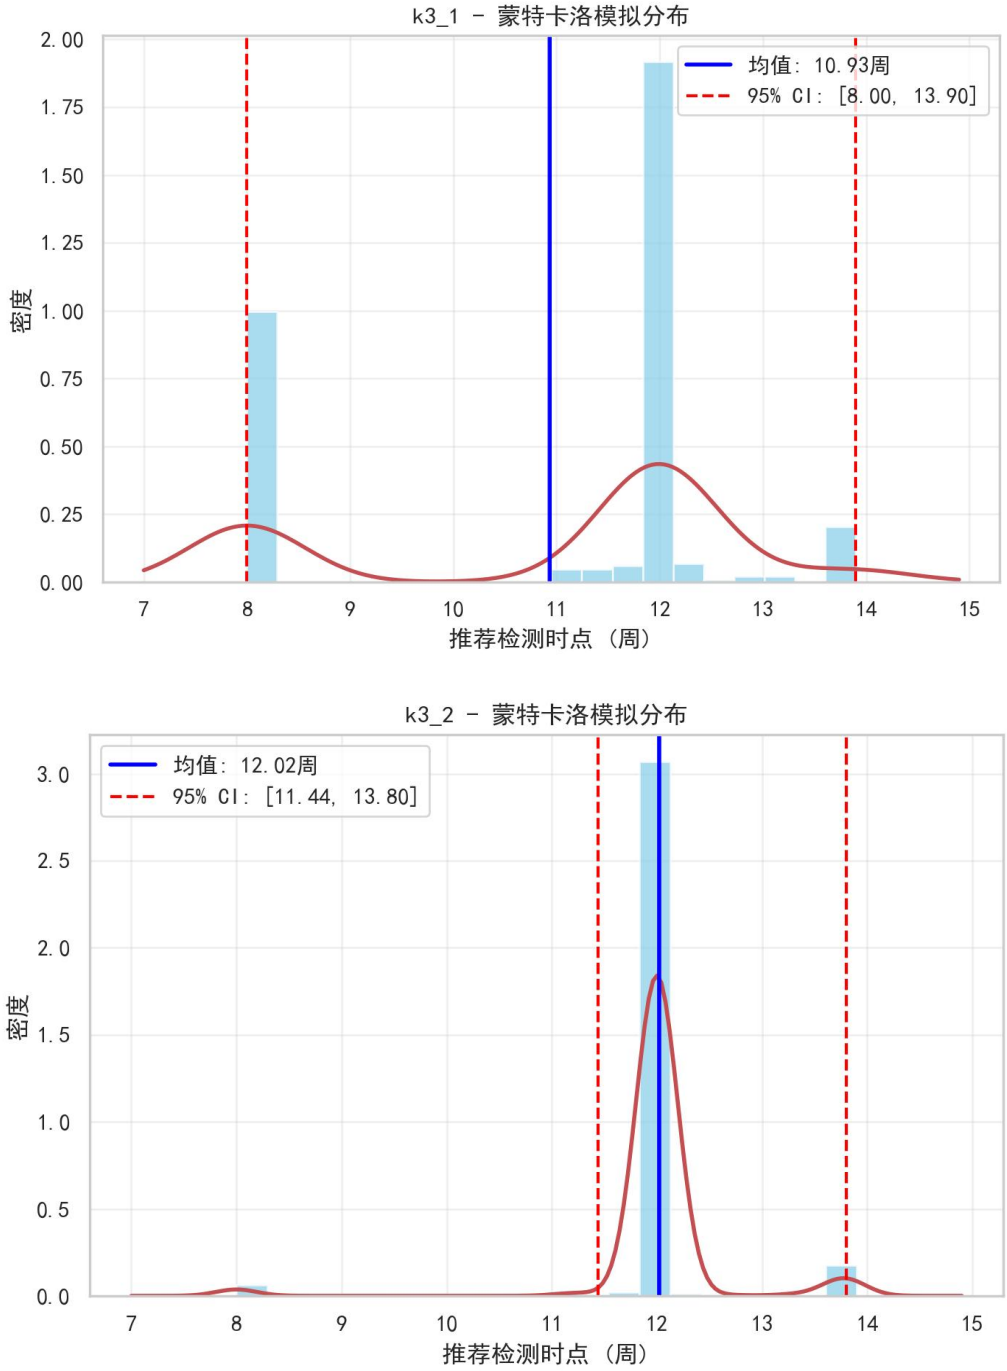

图 5-17 蒙特卡洛模拟分布直方图

可以发现，95%的模拟值落在[18.5, 20.5]周这个相对狭窄的区间内。这意味着尽管模型参数存在估计误差，但我们推荐的预测时间仍然是一个非常可靠的结果，uncertainty 较小。即便考虑模型参数估计的误差，最佳检测时点的推荐值也在一个较小的范围内变动，这增强了我们结论的可靠性。

此外，Monte Carlo 与 Bootstrap 得到的t^*分布直方图如下，

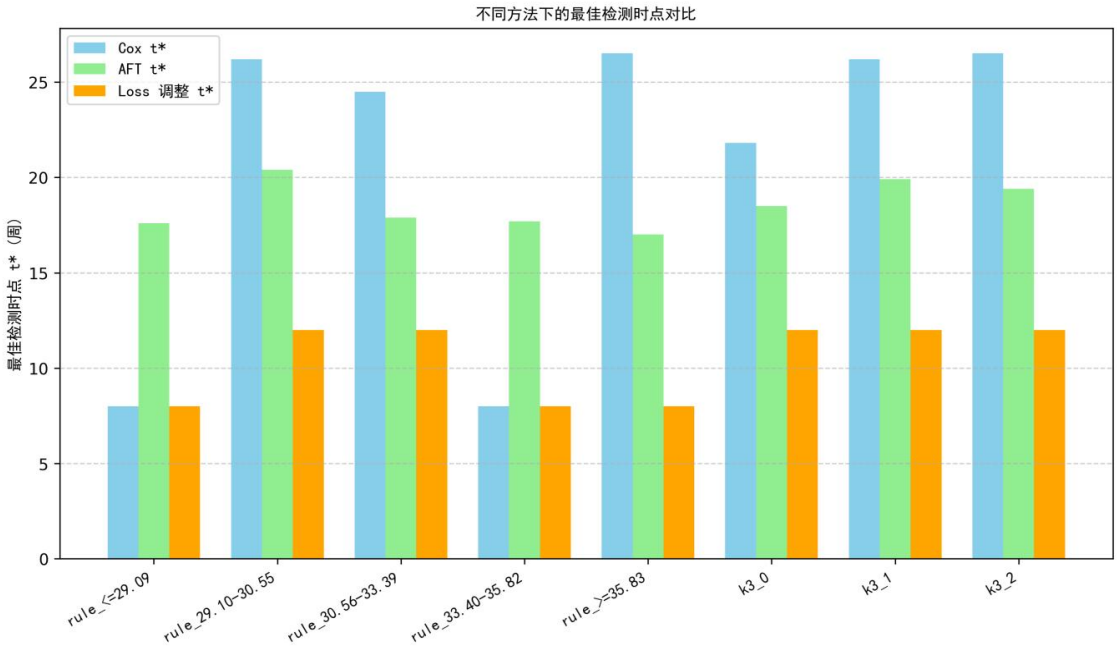

图 5-18 最优检测时间对比图

在规则分组下，不同 BMI 区间的最佳检测时点存在差异。例如，BMI 为 28–32 组的最佳检测时点约为 20.4 周，而 BMI≥35.83 组则提前至约 16.4 周。这说明高 BMI 人群可能因血容量稀释效应，导致 Y 染色体浓度上升模式不同，检测时点呈现出更早或更分散的特征。

相比之下，聚类分组的结果更为集中和稳定。三类亚群的最佳检测时点均位于 18 周左右，并且 Bootstrap 区间整体落在 16–26 周之间，提示聚类分组能有效降低 BMI 单一划分带来的波动性，揭示更隐含的人群模式。

最后，Monte Carlo 和 Bootstrap 分析不仅验证了结果的稳健性，也为推荐检测时点提供了统计置信区间支持。聚类分组在表现出的稳定性和可推广性上优于规则分组，即考虑基于多指标的综合分组的策略会更优。

5.5 问题四模型的建立与求解

本节研究的目标是判定女胎是否为任一（13、18 和 21 号）染色体异常，并基于数据构建一个可执行的判定规则。为此，首先将 X 染色体及上述染色体的 Z 值、GC 含量、读段数及相关比例、孕妇体征信息纳入考虑，随后对这些候选变量与染色体异常情况进行相关性分析与特征筛选，确定对异常判定具有显著作用的关键变量。在此基础上，结合模型的评估结果与判别性能，建立并提出一套适用于女胎染色体异常检测的判定规则。

5.5.1 数据准备和质控

本节处理的数据对象是附件女胎检测数据，对该数据集进行以下处理：

1、单独创建标签列：畸形儿的每种体征都有对应的异常决定染色体，如唐氏综合征由 21 号染色体浓度确定。为了能够准确识别每个女胎儿所患疾病，在原始数据上对每条染色体单独建一个标签列。其中 T13 表示 13 号染色体是否异常；同理 T18 与 T21 表示相同的含义。

2、处理缺失值：根据题意染色体的非整倍体是女胎孕妇异常的判定结果，故对该列进行缺失值处理，将 T13、T18 和 T21 记录填充为数量异常=1，空白=0。

3、数据质控（QC）：本研究数据中，部分孕妇存在有多次采血多次检测或一次

采血多次检测的情况，需要对重复检测数据进行过滤与质量控制。基于测序数据的核心指标，我们将样本划分为以下三类[8]：

•不合格（Fail）:原始读段数＜P2、比对的比例<80%、重复率＞P95，GC 含量　不属于[38%, 62%]且偏差极大；

•灰区（Gray）：原始读段数落在 P2~P10、重复率落在 P90~P95 或者|GC−0.5| >0.10，即表示接近阈值。

• 合格（Pass）：其余。

在样本筛选过程中，首先剔除所有 QC=Fail 的记录；随后后在剩余记录中，为每位孕妇保留唯一一条代表记录，筛选原则如下：优先选择 QC=Pass 的样本；若同一孕妇存在多条 Pass 记录，则进一步选择孕周更合适的一次；若仍存在多条候选，则选择原始读段数最高的样本。若该孕妇仅有 QC=Gray 的结果，则选取孕周更合适的一次，同时将该个体整体标记为灰区，建议复检。

经过上述步骤处理后，最终得到用于后续建模与分析的清洁数据集。

5.5.2 候选变量的探索性分析

1、Z 值与 QZ 特征的探索性分析

为评估各变量与染色体异常的关系，首先对观察 13、18、21 号染色体的 Z 值在不同分组的差异，绘制每条染色体 Z 值在正常与异常样本中的直方图与箱线图（仅展示 13 号染色体，其余在附录 1）：

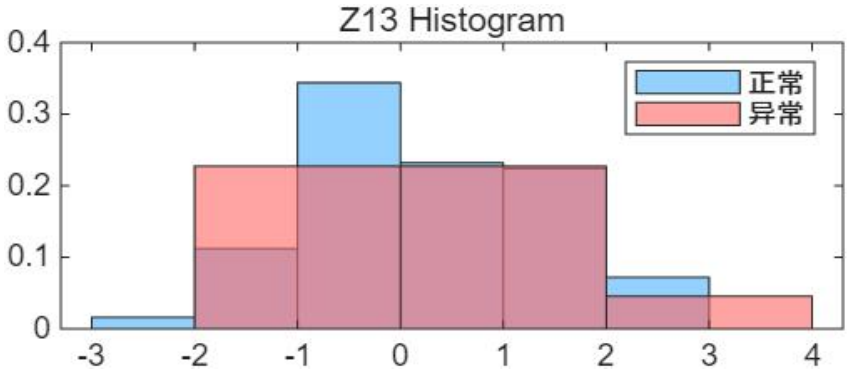

图 5-19 13 号染色体 Z 值分布直方图

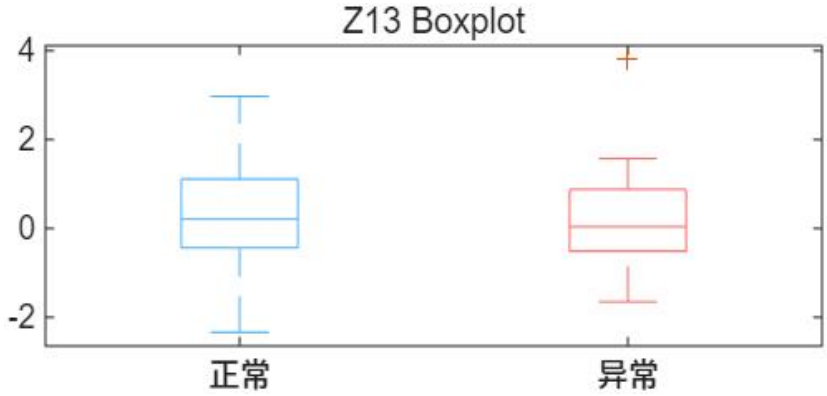

图 5-20 13 号染色体 Z 值箱线图

从每条染色体 Z 值分布直方图和箱线图显示可以看出，正常组和异常组的分布非常重叠，没有明显的分界点，而是两类都集中在-2 到+3 之间。故用单个染色体 Z 值做阈值判定可能几乎没有区分力。

接下来，为了评价这两类综合指标在异常检测中的判别性能，计算并绘制基于最

大 Z 值和平均 Z 值的 ROC 曲线（仅展示 Zmax 的 ROC 曲线，Zmean 在附录 1 可见）：

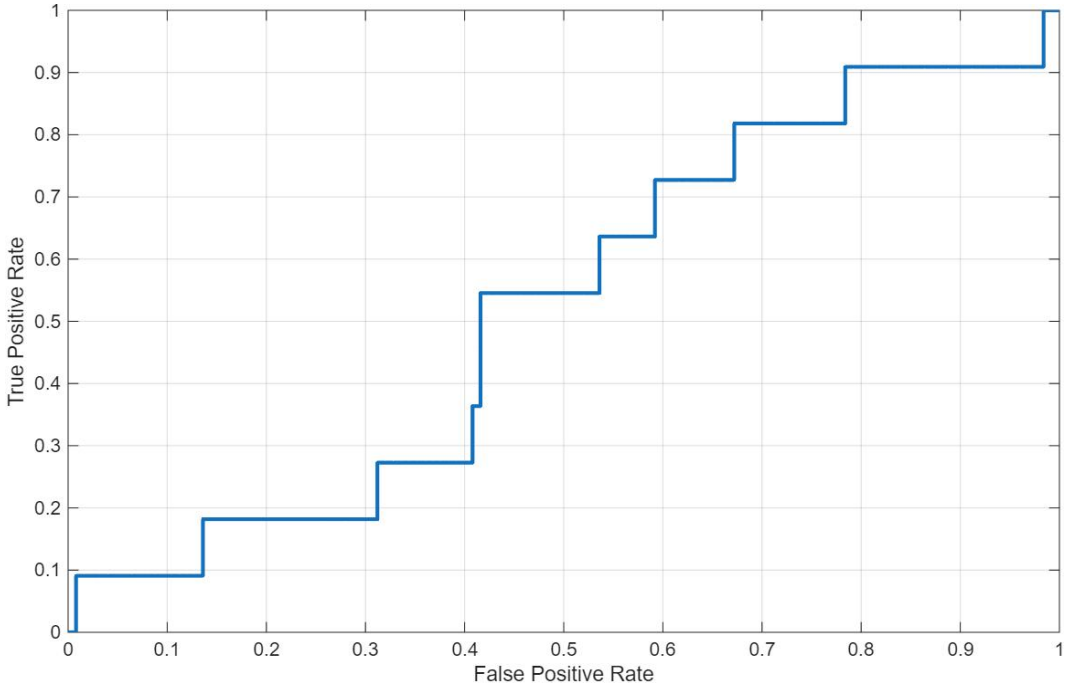

图 5-21 Z_{max}ROC 曲线

其中，

$$Z_{max} = Max(Z_{13}, Z_{18}, Z_{21}), \quad Z_{mean} = \frac{Z_{13} + Z_{18} + Z_{21}}{3} \tag{5-21}$$

两者的 AUC 均接近 0.52，接近随机分类器 (0.5)，说明 Zmax 和 Zmean 几乎没有判别能力，说明这批样本本身 Z 值和标签关系很弱。

同时，对测序质量控制（QC）相关指标，包括原始读段数、比对比例、重复率 以及总体 GC 含量，分别在合格样本、不合格样本及灰区样本中进行分布对比，采用 t 检验评估不同分组间的差异显著性，探讨测序质量对异常判定的潜在影响。

QC 相关指标	正常均值	异常均值	P 值
原始读段数	5.26×10^6	4.99×10^6	0.77
在参考基因组上比对的比例	0.81	0.81	0.33
重复读段的比例	0.03	0.03	0.39
总体 GC 含量	0.40	0.40	0.80

表 5-7　QC 指标 t 检验显著性结果

根据表 5-7，QC 指标在正常 vs 异常之间没有显著差异，说明 QC 不是主要影响判定的因素。同时，这也表明前文质控过滤策略合理。因为 QC 没有在两组间产生系统性差异，则说明清洁数据的剔除步骤已经消除了大部分与测序质量相关的偏差。

综上，单个 QC 指标或 Z 值不具备太强的区分力。核心还是要回到多个候选变量的综合判断上来提升区分力。如可以添加孕妇体征信息（孕周、BMI、年龄） 来提升区分力。

2、基线模型

探索性分析结果表明，单一 Z 值或 QC 指标在区分正常与异常样本时判别力有限，难以作为可靠依据。然而，Z 值阈值法仍是临床检测的常用基线方法。本研究在探索性分析后，首先对基线模型进行评估，以作为后续改进的对照；随后引入多维特征并结合机器学习方法，对灰区样本进行二次判定，以期提升整体灵敏度与特异度。

本节采用的基线模型是改进的双阈值 Z 值法[9]，对 13、18 和 21 号染色体的异常进行判定，其判定规则如下：

异常：若某条染色体的 Z 值 ≥3.5，则判定该染色体存在非整倍体异常；

正常：若某条染色体的 Z 值 ≤2.5，则判定该染色体正常；

灰区：若某条染色体的 Z 值位于 2.5 与 3.5 之间，则判定结果不确定，建议复检。

为全面评价其在本数据集中的判别性能，我们进一步基于真实标签计算了混淆矩阵，并据此得出灵敏度、特异度、异常预测值（PPV）和正常预测值（NPV）等指标，以量化该方法在不同维度下的表现。

灵敏度	特异度	PPV	NPV	灰区占比
0.091	0.992	0.500	0.922	0.044

表 5-8 双阈值 Z 值法评估指标

结果显示，双阈值法灵敏度仅 0.091，异常检出率极低；而特异度达 0.992，几乎不会误报，说明该方法对正常孕妇判定可靠，但对异常孕妇识别不足。其 PPV=0.500，稳定性有限；NPV=0.922，虽能较好排除异常，但仍存在漏检。灰区比例仅 4.4%，表明大多数样本 Z 值远离阈值区间。总体而言，双阈值法偏向保守，误报率低且漏诊率高，提示需引入多维特征与机器学习模型以提升异常检出能力。

5.5.3 特征工程与机器学习模型选择

1、特征工程

本节讨论的候选特征包含 15 个，将其划分为 4 类特征：

- 核心特征：13、18、21 染色体 Z 值
- 辅助特征：X 染色体 Z 值、X 染色体浓度
- 质量（QC）特征：原始读段数、比对比例、重复率、总体 GC 含量、各染色体 GC 含量
- 个体特征：孕周、BMI、年龄

为了保证输入模型更稳健，对所有连续特征做标准化，并构造 4 个派生特征：Z_{max}、Z_{mean}、GC_{dev} 和 GB，其中，Z_{max} 反映异常信号最强的一条染色体；Z_{mean} 反映整体异常倾向，可平滑掉单条染色体的波动； GC_{dev} 衡量样本 GC 含量与 0.5 的偏离程度；

$$GC_{dev} = |GC - 0.5| \tag{5-22}$$

另外，孕周（GA）与母体 BMI 可能共同影响胎儿游离 DNA 浓度，进而影响 Z 值分布，GB 用于是二者的交互项。

$$GB = GA \times BMI \tag{5-23}$$

综上，共有 19 个候选特征。

step1 相关性检查

计算候选特征间的相关性系数，检查变量间的相关性，筛选有效特征。下面绘制相关性系数的热力图：

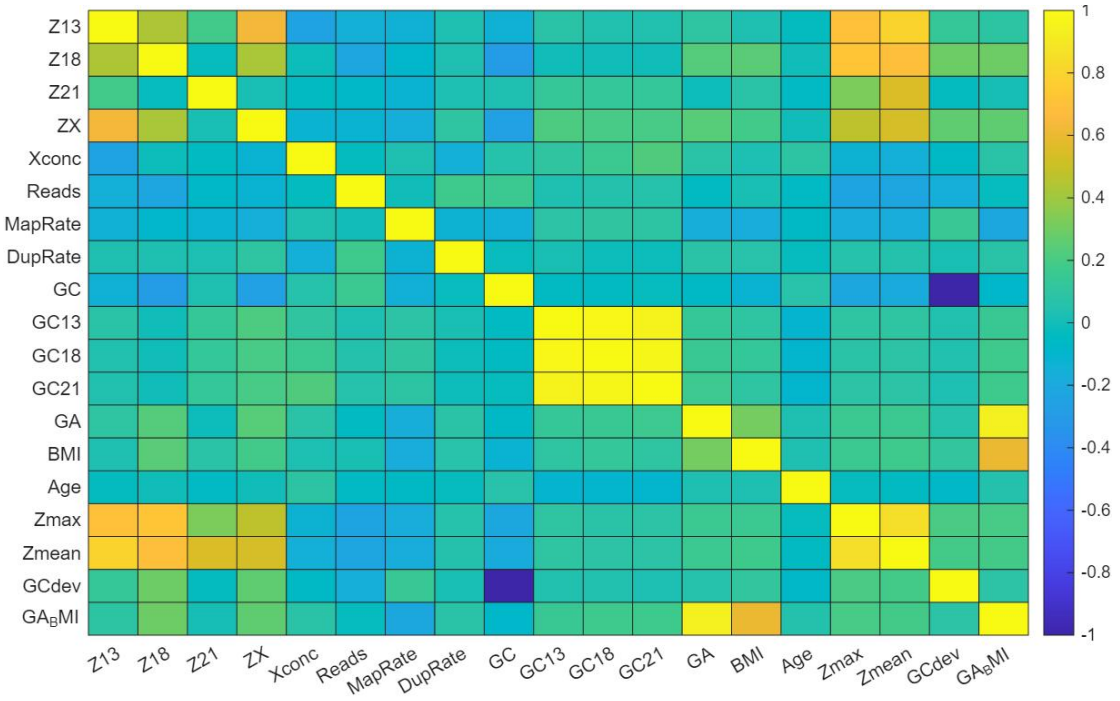

图 5-22 相关性系数热力图

从图中可以看到：Z13、Z18、Z21 与 Zmax、Zmean 高度相关、孕周 (GA) 与 GB 强相关、GC 与 GC13/GC18/GC21 也高度相关。说明在进入模型之前，必须做特征筛选，否则会有严重的多重共线性。

step2 共线性检验 VIF

VIF 判定规则：VIF < 5，则安全；VIF 5~10，可能有问题；VIF > 10，强多重共线性，需要剔除。对本节的真实数据集 VIF 值的计算结果如下：

特征	VIF	特征	VIF
13 号染色体 Z 值	inf	18 号染色体 GC 含量	45.317
18 号染色体 Z 值	inf	21 号染色体 GC 含量	20.447
21 号染色体 Z 值	inf	孕周	201.61
X 染色体 Z 值	2.136	BMI	35.81
X 染色体浓度	1.3464	年龄	1.0481
原始读段数	1.1829	Z_{max}	4.6584
比对比例	1.2393	Z_{mean}	inf
重复率	1.1222	GC_{dev}	inf
总体 GC 含量	inf	GB	291.4
13 号染色体 GC 含量	33.578		

表 5-9 候选特征量的 VIF 值（注：VIF = Inf 完全共线性）

根据 VIF 判定规则以及各变量间的相关性系数热力图，丢弃 Zmean、Zmax、各染色体 GC 含量、GB 共 6 个特征，保留 13 个特征。

step3 筛选效果验证

对筛选保留的 13 个特征重新进行相关性分析和 VIF 值计算，验证筛选结果的合理性，由可视化结果和相关 VIF 计算结果（见附录 2）可知：

相关性热力图整体颜色比较“冷”，说明绝大部分特征之间相关性较低，经过筛选后，特征之间的相关性已经基本合理。最小 VIF = 1.02，最大 VIF = 2.09，所有 VIF <

5，远低于一般认为存在严重共线性的阈值，说明这些特征集合不存在明显多重共线性问题筛选效果良好。

step4 模型驱动的二次特征筛选

使用逻辑回归（L1 正则化）模型与随机森林模型的联合筛选，确定具有较强判别力的核心特征集。首先针对逻辑回归与随机森林两种模型，分别在不同阈值下计算其性能指标，并绘制性能曲线如下：

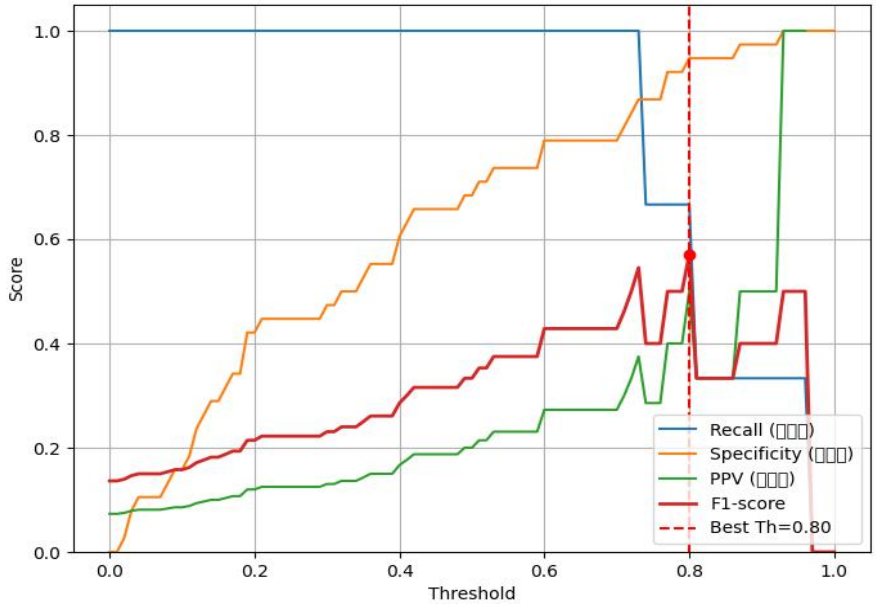

图 5-23 逻辑回归模型不同阈值下的性能指标

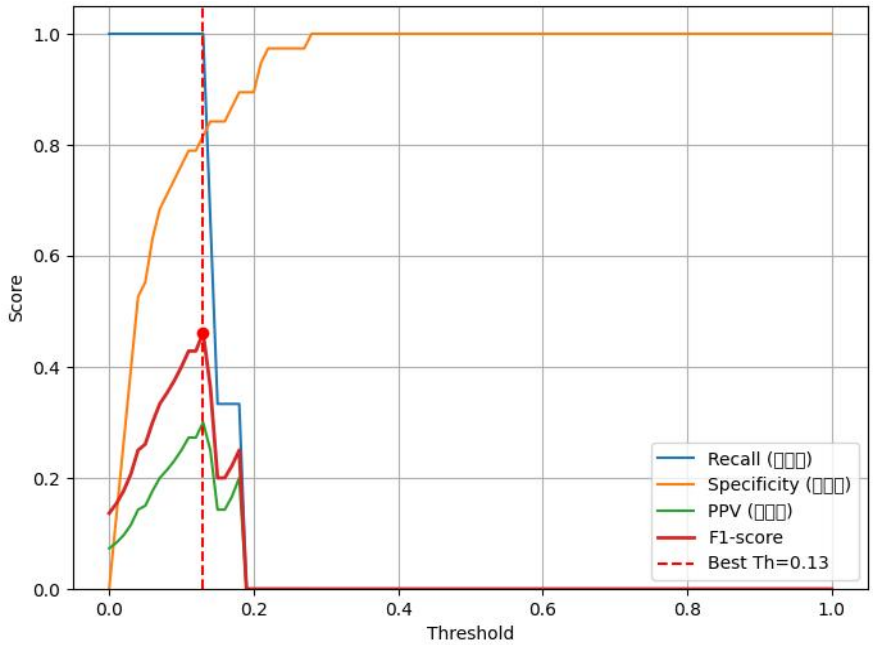

图 5-24 随机森林模型不同阈值下的性能指标

图 5-23 和图 5-24 得到最适配本研究需求的最优模型阈值：逻辑回归为 0.8，随机森林为 0.13。

接下来分别在两个模型中完成对候选特征的排序，其中逻辑回归模型中，通过引入 L1 正则化，将不显著特征的系数压缩为零，从而仅保留对预测具有显著贡献的变量，并以非零系数的绝对值大小作为特征重要性依据；在随机森林模型中，特征的重

要性由其在所有决策树中带来的不纯度下降量累积而得，贡献越大则重要性越高。

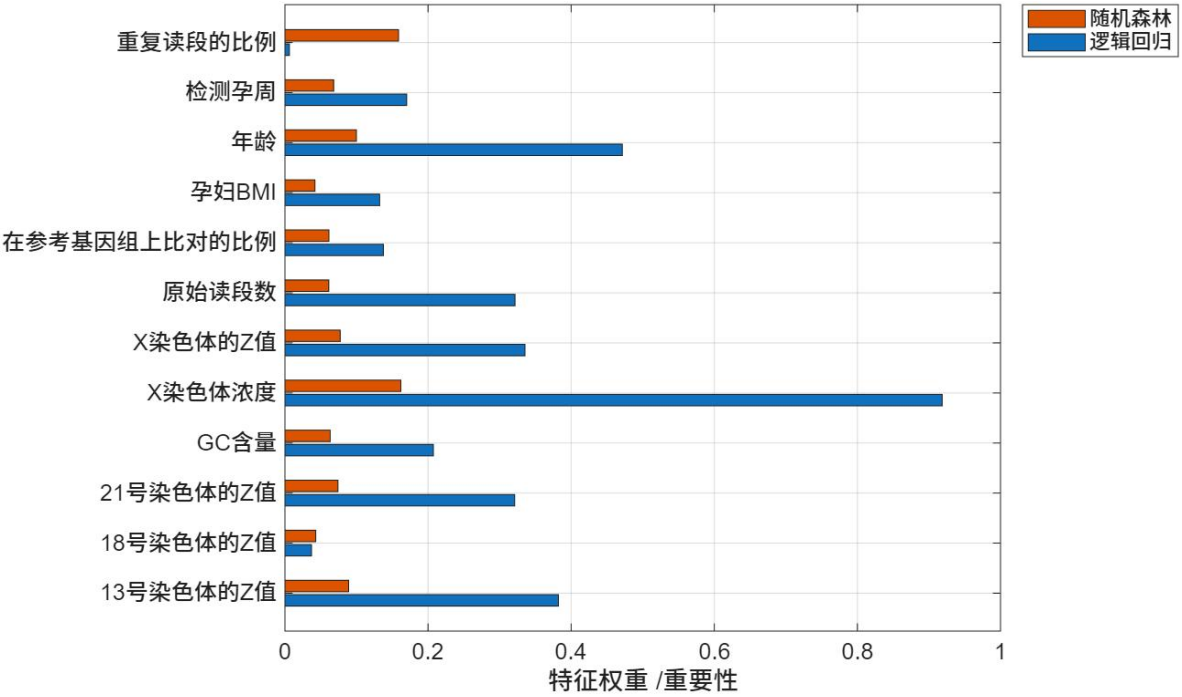

图 5-25 逻辑回归 vs 随机森林特征重要性对比

根据图 5-25，综合考虑两种模型的特征模型排名，确定以下最终推荐的特征集 6 个核心变量：X 染色体浓度、年龄、13 号染色体 Z 值、X 染色体 Z 值、21 号染色体 Z 值、重复读段比例

2、两种机器学习模型判别评估

使用 ROC 曲线选择判别能力更好的机器学习模型。在 ROC 曲线中，曲线越往左上角靠近，说明在各种阈值下，模型能更好地兼顾低误报和高召回，并且计算 ROC 曲线下的面积来比较两个模型区别异常区的能力，绘制两个模型的 ROC 曲线如下：

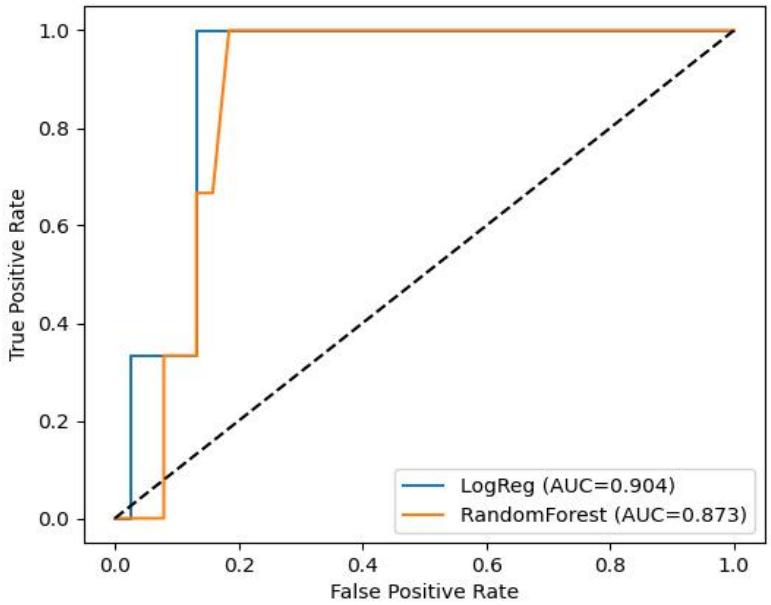

图 5-26 逻辑回归 vs 随机森林 ROC 曲线（注：黑色虚线表示随机猜测水平）

图 5-26 中两条曲线都明显高于对角线，说明两个模型均具有较好的区分能力。逻辑回归的 AUC 是 0.904，高于随机森林，说明逻辑回归模型整体判别能力优于随机森

林，在该数据集上表现更佳。且在低 FPR（假阳性率）区间内更陡峭，说明在控制误报率较低时，它能捕捉到更多的真正例，更适合异常病例漏诊成本高的场景。

5.5.4 女胎异常鉴定规则制定

综合以上研究，选出判定核心特征集为：X 染色体浓度、年龄、13 号染色体 Z 值、X 染色体 Z 值、21 号染色体 Z 值、重复读段比例；二次分类的模型：逻辑回归+L1 正则化，其中模型阈值设置为 0.13。

1、综合判定（任一染色体异常则判定女胎异常）

Step1 采用双阈值基线规则对样本进行初步分类：

若 $Z_{max} \geq 3.5$ 则判定为异常，直接输出，不进入模型；

若 $Z_{max} \leq 2.5$ 则判定为正常，直接输出，不进入模型；

若 $2.5 < Z_{max} < 3.5$ 则判定为灰区，进入模型判定。

Step2 使用逻辑回归模型计算染色体异常概率

对于灰区样本，引入逻辑回归+L1 正则化模型，使用核心特征集计算个体发生 13/18/21 号染色体任一异常的概率 p。随后结合优化得到的模型阈值 0.13，进行二次分类：

若 $p \geq 0.13$ 则判定为 异常；

若 $p < 0.13 \rightarrow$ 判定为 正常；

这时能够判断女胎个体是否异常，但不能确切的知道女胎的患病类型，为研究女胎每条染色体的异常情况，可以将判定方法拓展，如下：

分染色体判定（分别预测 13 号、18 号、21 号染色体的异常风险）

Step1 对每条染色体单独计算 Z 值；

Step2 应用单染色体双阈值法：

若 $Z \geq 3.5 \rightarrow$ 判定该染色体异常；

若 $Z \leq 2.5 \rightarrow$ 判定该染色体正常；

若 $2.5 < Z < 3.5 \rightarrow$ 进入模型判定。

Step3 使用逻辑回归模型计算染色体异常概率

将该染色体的核心特征集输入模型，计算该染色体异常概率 P，并结合最优阈值给出判定结果（异常/正常)。

六、 模型的评价、改进与推广

6.1 模型的优点

在问题二的分析中，我们通过建立综合损失函数，实现了对“检测过早导致测序失败风险”和“检测过晚导致干预延迟风险”的权衡，从而使最佳检测时点的确定更加符合临床实际。同时，引入 Monte Carlo 模拟算法，对检测误差可能带来的影响进行了量化处理，进一步提升了模型结论的稳健性。在数据分组方面，结合样本分布特点，采用分位数与临床标准相结合，并对边缘情况进行合并的多策略分组方法，避免了单纯等宽分组带来的样本分布不均问题，从而提高了分析结果的稳健性和临床可解释性。

在男胎 Y 染色体浓度达标时间受多种因素影响的前提下，问题三采取了 Cox 和 AFT 综合考量的生存模型，适宜各类孕妇。聚类分组加强模型的稳健性，且在最后引入了随时函数，充分贴合临床实际。

问题四采用逻辑回归（L1 正则化）与随机森林模型相结合，并针对灰区样本设

计二次判定机制。逻辑回归具备特征筛选和结果可解释性，随机森林能捕捉非线性关系并提高判别力，两者互补提升模型稳健性。同时，灰区二次判定减少了无结论比例，降低复检率，增强了方法的临床实用性。结果表明，该方法在保持特异度≈0.99 的同时显著提高灵敏度和异常检出率，整体优于传统 Z 值阈值法，为 NIPT 在女胎异常检测中提供了更可靠的判定框架。

6.2 模型的缺点

问题二中对风险函数进行了简化处理：晚期风险函数采用分段线性形式，虽然便于建模，但可能忽略实际临床中风险随孕周变化的非线性特征。

问题三模型中的损失函数权重的选择有一定主观性，而且若删失率高或某 BMI 子组样本量过小，分组结果的 Bootstrap 计算得到的置信区间会显著扩大。

6.3 模型的推广

基于 Logistic 回归与风险函数加权的决策优化模型推广，增加个体化预测，通过将 Logistic 模型参数与个体特征建立联系，可实现个体化的 NIPT 时点推荐，而不仅仅是分组层面的结论，提高最优 NIPT 时点与个体的适配性。

生存分析模型可推广引入广义混合效应模型（GLMM），处理“同孕妇多次检测”的纵向相关性，可以增强预测能力和强化解释性。

本研究所提出的双阈值结合机器学习的判定方法，在女胎 13、18、21 号染色体异常检测中展现了良好的适用性与解释性。然而，该模型仍具有进一步推广与扩展的潜力。从方法论角度看，模型可在更大规模及不同测序平台的数据集上进行外部验证，以检验其稳健性与普适性；同时，当前逻辑回归与随机森林的框架，可推广至更复杂的机器学习方法，如梯度提升树或深度学习模型，以进一步提升判定性能。此外，特征集也可扩展至更多维度，如 CNV、甲基化或 cfDNA 片段化模式，从而实现多模态特征融合。

在应用层面，该模型不仅可由 13、18、21 号染色体拓展至其他常见非整倍体与微缺失综合征，还可进一步推广至男胎样本，实现性别无关的统一检测。同时，结合孕妇多次检测数据，可构建时间序列判定模型，提升异常检出率与稳定性。未来，随着算法优化与数据积累，该模型有望嵌入临床产前诊断流程，成为辅助决策工具，尤其在灰区样本的复检判定中提供有力支持。

七、 参考文献

[1]Alberry MS, Aziz E, Ahmed SR, Abdel-Fattah S. 常见非整倍体及其他药物的无创产前检测（NIPT）。Eur J Obstet Gynecol Reprod Biol. 2021年3月;258:424-429. doi: 10.1016/j.ejogrb.2021.01.008. 电子出版 2021年1月19日. PMID: 33550217.

[2]Penn State University4.2 - Residuals vsFits Plot,https://online.stat.psu.edu/stat462/node/117/，访问时间：2025年9月7日。

[3]Hou Y, Zhao Y,Ji B,et al.Factors affecting cell‐free DNA fetal fraction:statistical analysis of 13,661 maternal plasmas for non‐invasive prenatal screening.Human Genomics,2019,13(1): 62-72.

[4]Ellerbe,C. N. Gebregziabher,M., Egede,L.E.,Mauldin,P.D.,&Zhu,H. (2013).Quantifying the impact of gestational diabetes mellitus,maternal weight and race on birthweight via quantile regression.PLOS ONE,8(6), e65017

[5]Li Q,Wu W,Zhao Z,et al.Association between fetal fraction of cell-free DNA and small-for-gestational-age neonates,Frontiers in Medicine,https://www.frontiersin.org/articles/10.3389/fmed.2022.1011366/full ，访问时间：2025年9月7日。

[6]Hickey JM, et al.Monte Carlo sampling strategies for evaluating prediction error variance formulas, Genet Sel Evol,41:23-35,2009.

[7]Bianco A，Buja A,Geisser S.Robustness of logistic regression in the presence of contamination:a Monte Carlo study,Computational Statistics & Data Analysis,53(2):404-420,2009.

[8]Andrews, S.(2010).FastQC:A quality control tool for high throughput sequence data.Retrieved September 7,2025, from https://www.bioinformatics.babraham.ac.uk/projects/fastqc/

[9]Zhou, L., Zhang, F., Liu, Y., Shi, H., Wang, J., & Yu, X. (2021). The optimal cutoff value of the Z-score in NIPS. Chinese Journal of Prenatal Diagnosis. https://pubmed.ncbi.nlm.nih.gov/34367249

[10] ChatGPT，GPT-5 mini，OpenAI，2025-09-06

附录

附录 1

其他自变量与 Y 染色体浓度的散点图

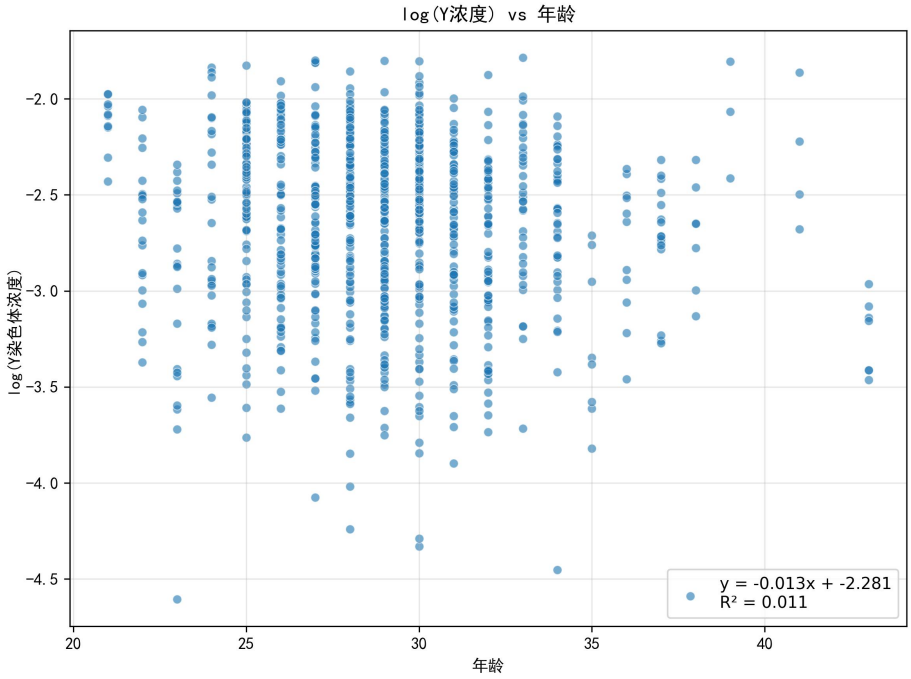

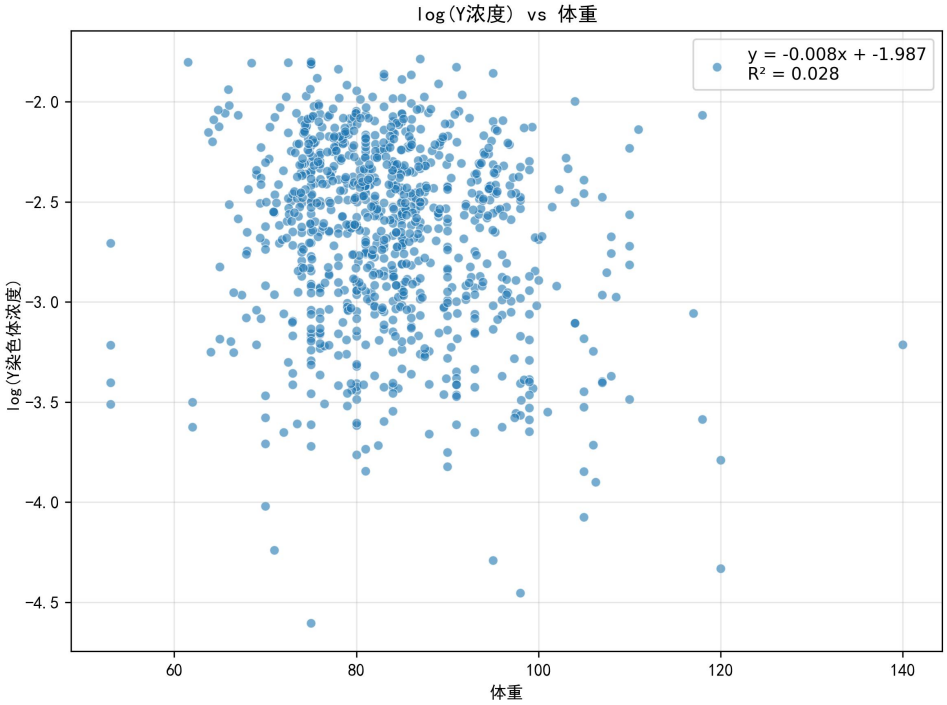

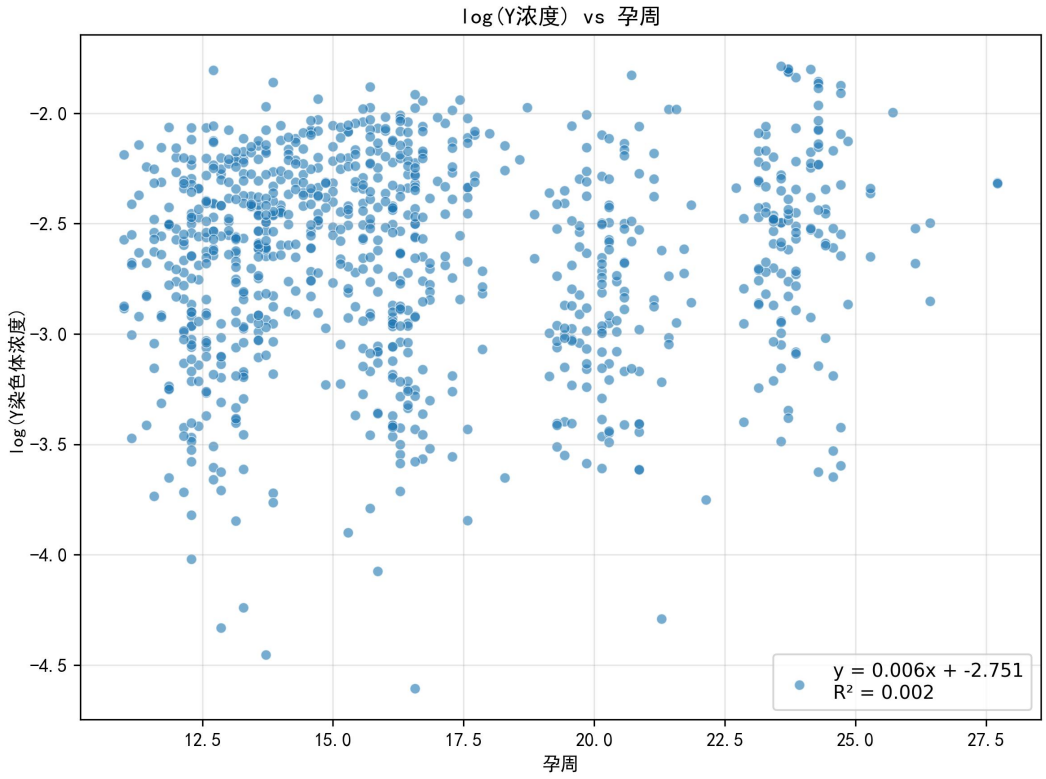

附录 2

介绍：每条染色体 Z 值在正常与异常样本中的直方图与箱线图

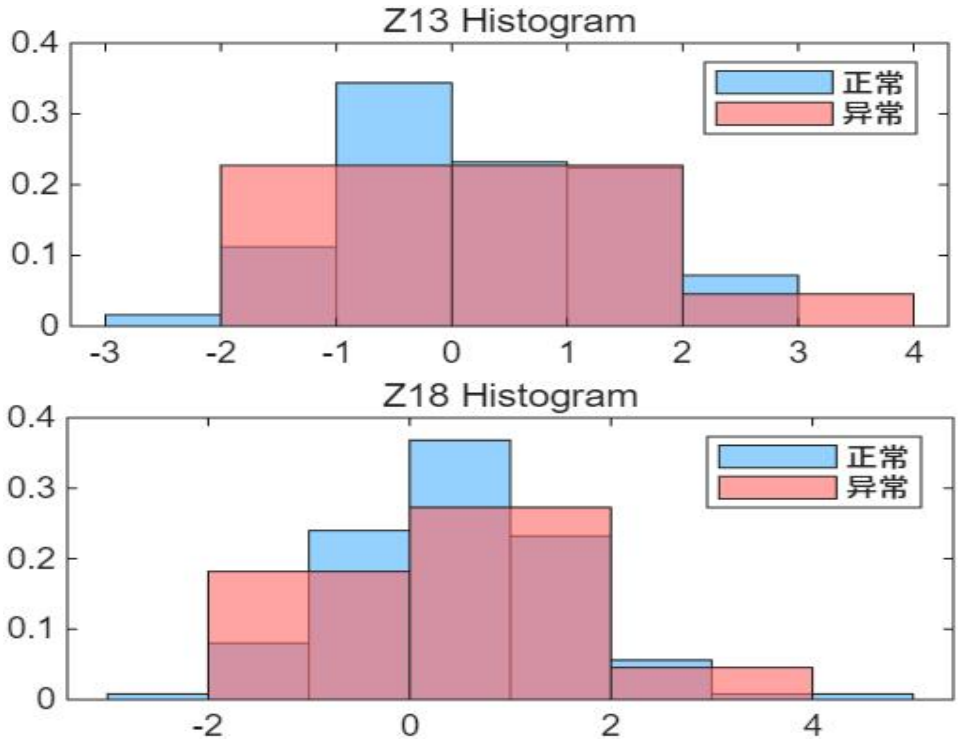

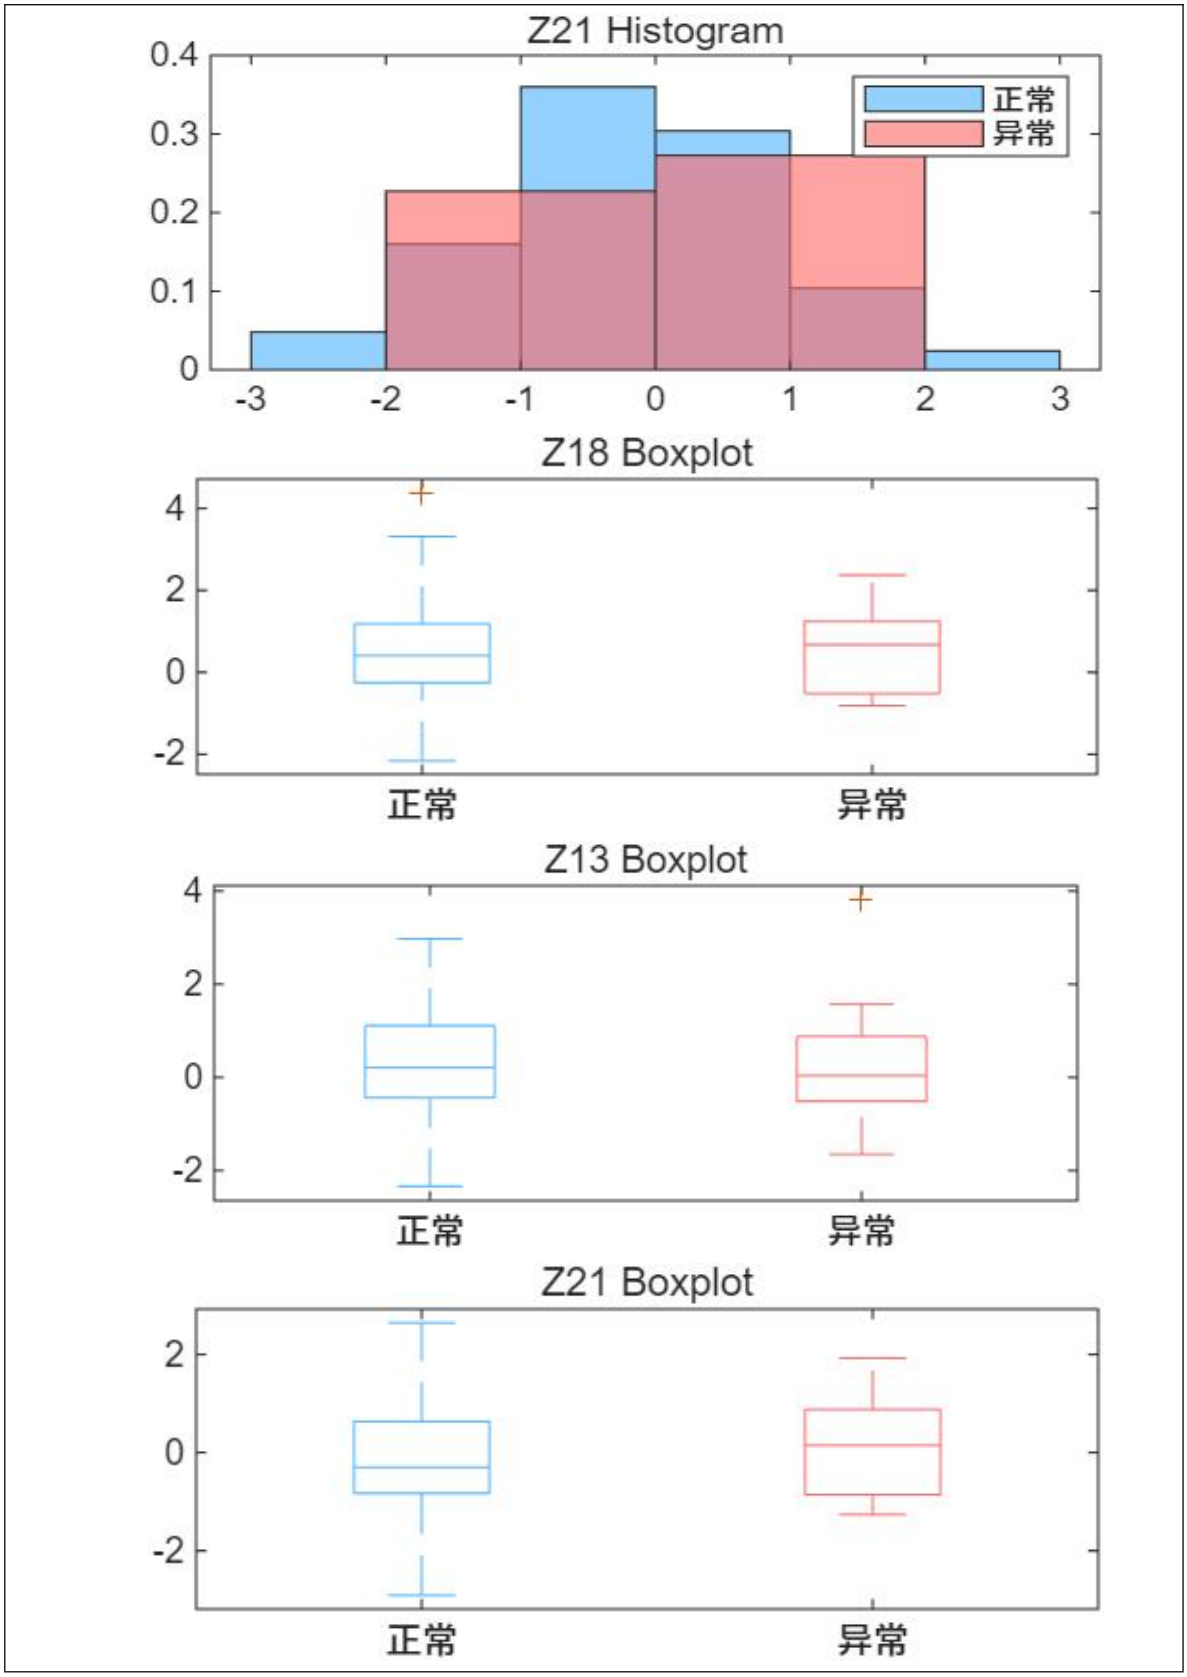
Z21 Histogram
正常
异常
0.4
0.3
0.2
0.1
0
-3
-2
-1
0
1
2
3
Z18 Boxplot
4
2
0
-2
正常
异常
Z13 Boxplot
4
2
0
-2
正常
异常
Z21 Boxplot
2
0
-2
正常
异常

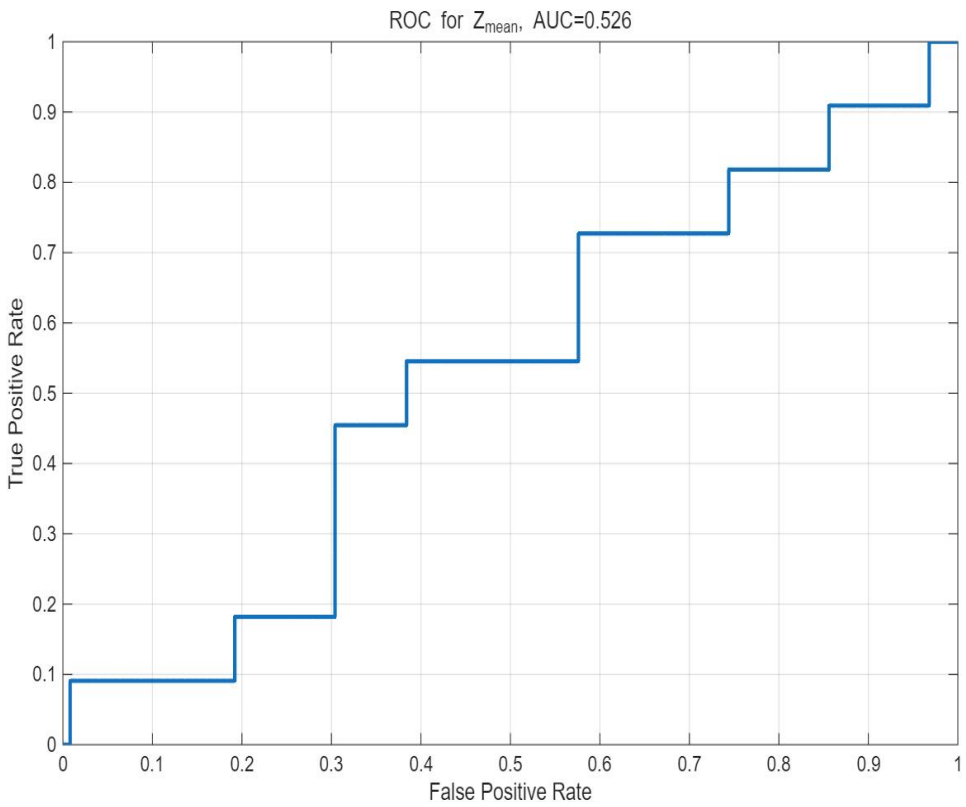

平均 Z 值的 ROC 曲线

附录 3

介绍：相关性分析筛选特征后的相关性系数热力图和 VIF 结果表

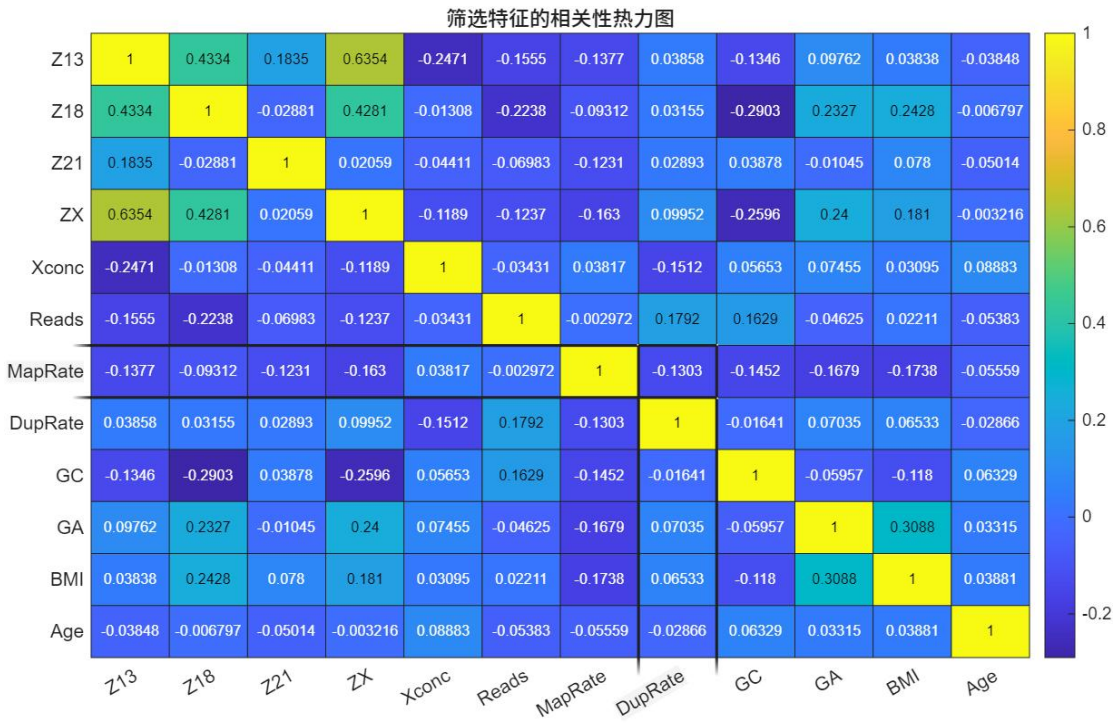

特征	VIF	特征	VIF
13 号染色体 Z 值	2.0861	比对比例	1.2393
18 号染色体 Z 值	1.5168	重复率	1.141
21 号染色体 Z 值	1.1024	总体 GC 含量	1.2088
X 染色体 Z 值	1.9757	孕周	1.1935
X 染色体浓度	1.124	BMI	1.216
原始读段数	1.1332	年龄	1.0244

附录 4

介绍：问题一多元回归模型的 python 代码

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
from statsmodels.graphics.gofplots import qqplot
from sklearn.model_selection import KFold, cross_val_score
from sklearn.linear_model import LinearRegression
from sklearn.metrics import make_scorer, mean_squared_error, r2_score
from statsmodels.stats.diagnostic import het_white, het_breuschpagan
# === 1. 读取数据 ===
df = pd.read_excel("cleaned.xlsx")
df_male = df[df['Y_conc'].notna()].copy()
df_male['log_Y_conc'] = np.log(df_male['Y_conc'] + 1e-10)
# 因变量
y = df_male["log_Y_conc"].astype(float)
# 自变量：BMI + 年龄 + 胎儿健康 + 孕周
X = df_male[["BMI_raw", "age", "fetus_healthy", "GA_weeks"]].copy()
# 处理分类变量 fetus_healthy（是/否 → 1/0）
X["fetus_healthy"] = X["fetus_healthy"].map({"是": 1, "否": 0}).astype(float)
# 添加常数项
X = sm.add_constant(X)
# === 2. 建立 OLS 模型 ===
model = sm.OLS(y, X).fit(cov_type="HC3")
print(model.summary())
# === 3. 残差诊断 ===
```

```
residuals = model.resid
fitted = model.fittedvalues
# (1) QQ 图
qqplot(residuals, line="s")
plt.title("QQ Plot of Residuals")
plt.show()
# (2) 残差 vs 拟合值图
plt.scatter(fitted, residuals, alpha=0.6)
plt.axhline(y=0, color="red", linestyle="--")
plt.xlabel("Fitted values")
plt.ylabel("Residuals")
plt.title("Residuals vs Fitted")
plt.show()
# === 4. 交叉验证 (10 折) ===
kf = KFold(n_splits=10, shuffle=True, random_state=42)
lin_reg = LinearRegression()
mse_scores = cross_val_score(
    lin_reg, X.drop(columns="const"), y,
    scoring=make_scorer(mean_squared_error, greater_is_better=False),
    cv=kf
)
r2_scores = cross_val_score(
    lin_reg, X.drop(columns="const"), y,
    scoring="r2",
    cv=kf
)
print("\n=== 交叉验证结果 (10 折) ===")
print(f"平均 MSE: {-np.mean(mse_scores):.4f}")
print(f"平均 R² : {np.mean(r2_scores):.4f}")
# 可视化交叉验证结果
plt.figure(figsize=(6,4))
plt.boxplot([ -mse_scores, r2_scores ], labels=["MSE", "R² "])
plt.title("Cross-validation Results (10-fold)")
plt.show()
# === 5. 异方差检验 ===
white_test = het_white(residuals, model.model.exog)
bp_test = het_breuschpagan(residuals, model.model.exog)
print("\nWhite 异方差检验: p-value =", white_test[1])
print("Breusch-Pagan 异方差检验: p-value =", bp_test[1])
```

附录 5

问题二与问题三数据预处理的 python 代码

```
import pandas as pd
import numpy as np
```

```
import os
# ---------------- 首先参数设置 ----------------
INPUT_PATH = r"C:\Users\admin\Desktop\university\数学建模拿下\2025 赛题\C 题\cleaned.csv"
OUTDIR = r"C:\Users\admin\Desktop\university\数学建模拿下\2025 赛题\C 题\preprocess_out"
os.makedirs(OUTDIR, exist_ok=True)
# ---------------- 接下来我们来读取数据 ----------------
df = pd.read_csv(INPUT_PATH)
# 一定要确保关键字段正确类型
df['GA_days'] = pd.to_numeric(df['GA_days'], errors='coerce')
df['BMI_raw'] = pd.to_numeric(df['BMI_raw'], errors='coerce')
df['Y_conc'] = pd.to_numeric(df['Y_conc'], errors='coerce')
df['test_date'] = pd.to_datetime(df['test_date'], errors='coerce')
# ---------------- 然后孕周换算（天数 -> 周数，保留两位小数） ----------------
df['GA_weeks'] = (df['GA_days'] / 7).round(2)
# ---------------- 提取数据中的最早达标时间 ----------------
# 条件：Y_conc >= 4% (0.04)
df_pass = df[df['Y_conc'] >= 0.04].copy()
# 输出每个孕妇首次达标记录（GA_weeks + test_date + Y_conc）
first_pass = (
    df_pass.sort_values(['patient_id', 'GA_weeks'])
            .groupby('patient_id', as_index=False)
            .first()[['patient_id','GA_weeks','test_date','Y_conc']]
)
# ---------------- 拼接需要用到的孕妇信息 ----------------
patient_info = (
    df.groupby('patient_id').agg(
        age=('age','first'),
        height_cm=('height_cm','first'),
        weight_kg=('weight_kg','first'),
        BMI=('BMI_raw','mean'),
        gravidity=('gravidity','first'),   # 怀孕次数 (AC 列)
        parity=('parity','first')          # 生产次数 (AD 列)
    )
).reset_index()

# 对最早达标信息进行合并
patient_summary = patient_info.merge(
    first_pass,
    on='patient_id', how='left'
).rename(columns={
    'GA_weeks':'first_reach_GA_weeks',
    'test_date':'first_reach_date',
    'Y_conc':'first_reach_Yconc'
})
```

```
# ---------------- 增加一列达标标志列 ----------------
patient_summary['reach_flag'] = ~patient_summary['first_reach_GA_weeks'].isna()
# ---------------- 保存最后的完整结果 ----------------
out_path = os.path.join(OUTDIR, "problem3_patient_summary.csv")
patient_summary.to_csv(out_path, index=False, encoding='utf-8-sig')
print("问题二数据处理完成 ☑ 输出文件：", out_path)
```

附录 6

问题二模型的求解代码

```
import matplotlib
matplotlib.use('Agg')  # 非交互式后端
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
# ---------------- 首先先设置中文字体 ----------------
plt.rcParams['font.sans-serif'] = ['SimHei', 'DejaVu Sans']
# ---------------- 对数据完成读取 ----------------
file_path = r"C:\Users\admin\Desktop\university\数学建模拿下\2025 赛题\C 题\problem2.csv"
df = pd.read_csv(file_path)
# ---------------- BMI 分组及参数 ----------------
bmi_groups = {
    '≤29.09': {'b': -6.6, 'k': 0.44},
    '29.10-30.55': {'b': -5.8, 'k': 0.43},
    '30.56-33.39': {'b': -5.3, 'k': 0.41},
    '33.40-35.82': {'b': -5.0, 'k': 0.39},
    '≥35.83': {'b': -4.8, 'k': 0.35},
}
# ---------------- 构建 Logistic 达标概率函数 ----------------
def p_logistic(t, b, k):
    return 1 / (1 + np.exp(-(b + k * t)))

# ---------------- 构造晚期风险函数 ----------------
def late_risk(t):
    t = np.array(t)
    risk = np.zeros_like(t, dtype=float)
    mask_mid = (t > 12) & (t <= 27)
    risk[mask_mid] = (t[mask_mid] - 12) / (27 - 12)
    risk[t > 27] = 1.0
    return risk
# ---------------- 构建损失函数 ----------------
def loss_function(t, b, k, w=1.0):
    return (1 - p_logistic(t, b, k)) + w * late_risk(t)
# ---------------- 蒙特卡洛模拟用于计算 t* 置信区间 ----------------
```

```
def monte_carlo_t_star(b, k, t_values, w=1.0, error_std=0.02, n_sim=500):
    t_star_list = []
    for _ in range(n_sim):
        b_sim = b + np.random.normal(0, error_std)
        k_sim = k + np.random.normal(0, error_std)
        losses = loss_function(t_values, b_sim, k_sim, w=w)
        t_star_sim = t_values[np.argmin(losses)]
        t_star_list.append(t_star_sim)
    return np.percentile(t_star_list, [2.5, 50, 97.5])
# ---------------- 计算最优 NIPT 时点 ----------------
t_values = np.arange(8, 30, 0.1)
best_times = []
fig, axs = plt.subplots(len(bmi_groups), 1, figsize=(8, 4*len(bmi_groups)))
for idx, (group, params) in enumerate(bmi_groups.items()):
    b, k = params['b'], params['k']
    p_values = p_logistic(t_values, b, k)
    risk_values = late_risk(t_values)
    # 计算蒙特卡洛 t* 置信区间
    t_low, t_median, t_high = monte_carlo_t_star(b, k, t_values, w=1.0, error_std=0.02, n_sim=500)
    # 绘图
    ax = axs[idx] if len(bmi_groups) > 1 else axs
    ax.plot(t_values, p_values, label='达标概率 p(t)')
    ax.plot(t_values, risk_values, '--', label='晚期风险')
    ax.axvline(t_median, color='red', linestyle='--', label=f'最佳 t*={t_median:.1f}周')
    ax.fill_betweenx([0,1], t_low, t_high, color='red', alpha=0.2, label='t* 置信区间')
    ax.set_title(f'BMI {group}')
    ax.set_xlabel('孕周 t')
    ax.set_ylabel('概率 / 风险')
    ax.grid(True)
    ax.legend()
    # 50%和 90%达标点
    t50 = -b / k
    t90 = (-b + np.log(9)) / k
    best_times.append({
        'BMI 组': group,
        't0_50%': round(t50,2),
        't90_达标': round(t90,2),
        '损失最优 t* (中位数)': round(t_median,2),
        't* 95% CI 下限': round(t_low,2),
        't* 95% CI 上限': round(t_high,2),
    })
plt.tight_layout()
plt.savefig(r"C:\Users\admin\Desktop\university\数学建模拿下\2025 赛题\C 题\best_nipt_times_groups.png", dpi=300)
plt.close()
```

```
# ---------------- 输出最终结果的表格 ----------------
result_df = pd.DataFrame(best_times)
print(result_df)
result_df.to_csv(r"C:\Users\admin\Desktop\university\数学建模拿下\2025 赛题\C 题\problem2_best_times_final.csv", index=False)
```

附录 7

问题三模型求解的 python 代码

```
import os, re, math
import matplotlib
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from lifelines import CoxPHFitter, WeibullAFTFitter
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from tqdm import tqdm
from matplotlib import font_manager
# 设置中文字体
plt.rcParams['font.sans-serif'] = ['SimHei', 'Microsoft YaHei', 'DejaVu Sans']
plt.rcParams['axes.unicode_minus'] = False  # 负号显示
matplotlib.rcParams['font.family'] = 'sans-serif'
# ---------------- Settings ----------------
INPUT_FILE = "problem3_patient_summary.xlsx"
OUTDIR = "problem3_outputs"
os.makedirs(OUTDIR, exist_ok=True)
T_GRID = np.arange(8, 30.1, 0.1)
WINDOW = (12, 27)
THRESH_Q = 0.95
# Loss weights (tune if needed)
W_MISS = 1.0
W_FAIL = 0.0
W_EARLY = 2.0
W_LATE = 1.0
W_VERY_LATE = 3.0
# Monte Carlo / bootstrap sizes (moderate defaults)
N_PARAM_MC = 500
N_OBS_MC = 200
N_BOOT = 300
RANDOM_SEED = 42
np.random.seed(RANDOM_SEED)
# Plot settings
sns.set(style="whitegrid")
```

```
# ---------------- Utilities ----------------
def sanitize_filename(s):
    if s is None:
        return "NA"
    s = str(s)
    s = re.sub(r'[<>:"/\\|?*\n\r\t]+', '_', s)
    s = s.strip()
    if len(s) == 0:
        return "NA"
    return s
def read_and_prepare(path=INPUT_FILE):
    df = pd.read_excel(path)
    df.columns = [c.strip() for c in df.columns]
    # Common renames
    rename_map = {}
    if "patient_id" in df.columns and "id" not in df.columns:
        rename_map["patient_id"] = "id"
    if "first_reach_GA_weeks" in df.columns and "time" not in df.columns:
        rename_map["first_reach_GA_weeks"] = "time"
    if "reach_flag" in df.columns and "event" not in df.columns:
        rename_map["reach_flag"] = "event"
    if rename_map:
        df = df.rename(columns=rename_map)
    # Ensure required columns exist
    required = ["id", "time", "event", "BMI", "age", "height_cm", "weight_kg", "gravidity", "parity"]
    missing = [c for c in required if c not in df.columns]
    if missing:
        raise ValueError(f"Missing required columns: {missing}")
    # Coerce types
    df["time"] = pd.to_numeric(df["time"], errors="coerce")
    df["event"] = df["event"].astype(int)
    for c in ["BMI", "age", "height_cm", "weight_kg", "gravidity", "parity"]:
        df[c] = pd.to_numeric(df[c], errors="coerce")
    # Drop rows missing time or BMI
    df = df.dropna(subset=["time", "BMI"])
    return df
def rule_bmi_groups(df):
    bins = [0, 29.09, 30.55, 33.39, 35.82, np.inf]
    labels = ["<=29.09", "29.10-30.55", "30.56-33.39", "33.40-35.82", ">=35.83"]
    df["BMI_group_rule"] = pd.cut(df["BMI"], bins=bins, labels=labels, right=True)
    return df
def cluster_groups(df, features=["BMI", "weight_kg", "height_cm"], k=3):
    X = df[features].fillna(df[features].median())
    scaler = StandardScaler()
```

```
    Xs = scaler.fit_transform(X)
    km = KMeans(n_clusters=k, random_state=RANDOM_SEED, n_init=20)
    df[f"BMI_k{k}"] = km.fit_predict(Xs)
    return df
def fit_cox(df_group, formula=None):
    cph = CoxPHFitter()
    if formula is None:
        formula = "BMI + age + height_cm + weight_kg + gravidity + parity"
    cph.fit(df_group, duration_col="time", event_col="event", formula=formula)
    return cph
def fit_aft(df_group, formula=None):
    aft = WeibullAFTFitter()
    if formula is None:
        formula = "BMI + age + height_cm + weight_kg + gravidity + parity"
    aft.fit(df_group, duration_col="time", event_col="event", formula=formula)
    return aft
def survival_from_cox(cph, X_row, tgrid=T_GRID):
    base = cph.baseline_survival_
    S0 = np.interp(tgrid, base.index, base.values.flatten())
    # compute xb
    beta_names = cph.params_.index.tolist()
    xb = 0.0
    for i, name in enumerate(beta_names):
        if name in X_row.index:
            try:
                xb += float(cph.params_.values[i]) * float(X_row[name])
            except Exception:
                xb += 0.0
    Sx = S0 ** np.exp(xb)
    return pd.Series(Sx, index=tgrid)
def survival_from_aft(aft, X_row, tgrid=T_GRID):
    Xdf = X_row.to_frame().T
    sf = aft.predict_survival_function(Xdf, times=tgrid)
    return sf.iloc[:, 0]
def compute_times_from_S(S_series, q=THRESH_Q):
    F = 1 - S_series.values
    T = S_series.index.values
    # t50 & t90
    t50 = float(T[(np.abs(F - 0.5)).argmin()])
    t90 = float(T[(np.abs(F - 0.9)).argmin()])
    idx = np.where(F >= q)[0]
    if len(idx) > 0:
        tstar = float(T[idx[0]])
    else:
```

```
        tstar = float(T[F.argmax()])
    return t50, t90, tstar
def loss_function(F_t, t_grid, w_miss=W_MISS, w_fail=W_FAIL, w_early=W_EARLY, w_late=W_LATE, w_very_late=W_VERY_LATE):
    t_grid = np.asarray(t_grid)
    L1 = w_miss * (1 - F_t)
    L2 = w_fail * 0.0
    L3 = w_early * (t_grid < WINDOW[0]).astype(float)
    L4 = w_late * (t_grid > WINDOW[1]).astype(float)
    L5 = w_very_late * (t_grid >= 28).astype(float)
    return L1 + L2 + L3 + L4 + L5
def argmin_loss(F_t, t_grid):
    L = loss_function(F_t, t_grid)
    idx = int(np.argmin(L))
    return float(t_grid[idx]), float(L[idx])
# ---------------- Group analysis ----------------
def analyze_group(df_group, group_name, outpref, w=1.5):
    summary = {"group": group_name, "n": len(df_group)}
    # representative covariates (median for numeric, mode for categorical)
    rep = {}
    for col in ['BMI', 'age', 'height_cm', 'weight_kg', 'gravidity', 'parity']:
        if col in df_group.columns:
            if df_group[col].dtype.kind in 'biufc':
                rep[col] = df_group[col].median()
            else:
                rep[col] = df_group[col].mode().iloc[0]
    Xrep = pd.Series(rep)
    # fit models
    cph = None
    aft = None
    try:
        cph = fit_cox(df_group)
        summary['cox_concordance'] = float(cph.concordance_index_)
    except Exception as e:
        summary['cox_concordance'] = np.nan
        print(f"[WARN] Cox failed for {group_name}: {e}")
    try:
        aft = fit_aft(df_group)
    except Exception as e:
        print(f"[WARN] AFT failed for {group_name}: {e}")
    # survival curves
    S_cox = None
    S_aft = None
    if cph is not None:
```

```
        S_cox = survival_from_cox(cph, Xrep)
        t50_cox, t90_cox, tstar_cox = compute_times_from_S(S_cox)
        summary.update({'t50_cox': t50_cox, 't90_cox': t90_cox, 'tstar_cox': tstar_cox})
    else:
        summary.update({'t50_cox': np.nan, 't90_cox': np.nan, 'tstar_cox': np.nan})
    if aft is not None:
        S_aft = survival_from_aft(aft, Xrep)
        t50_aft, t90_aft, tstar_aft = compute_times_from_S(S_aft)
        summary.update({'t50_aft': t50_aft, 't90_aft': t90_aft, 'tstar_aft': tstar_aft})
    else:
        summary.update({'t50_aft': np.nan, 't90_aft': np.nan, 'tstar_aft': np.nan})
    # === New: Loss function optimization (基于 Cox 累积概率 F(t)) ===
    if S_cox is not None:
        F_cox = 1 - S_cox.values
        t_grid = S_cox.index.values
        def late_risk(t):
            if t < 12:
                return 0
            elif 12 <= t < 28:
                return (t - 12) / (28 - 12)
            else:
                return 1

        losses = []
        for i, t in enumerate(t_grid):
            losses.append((1 - F_cox[i]) + w * late_risk(t))
        best_idx = np.argmin(losses)
        tstar_loss_cox = float(t_grid[best_idx])
        summary['tstar_loss_cox'] = tstar_loss_cox
        summary['lossval_cox'] = float(losses[best_idx])
    else:
        summary['tstar_loss_cox'] = np.nan
        summary['lossval_cox'] = np.nan
    # 保存 per-group summary CSV
    pd.DataFrame([summary]).to_csv(os.path.join(OUTDIR, f"{sanitize_filename(outpref)}_summary.csv"), index=False)
    # Plot survival curves
    fig, ax = plt.subplots(figsize=(7, 4))
    if S_cox is not None:
        ax.plot(S_cox.index, S_cox.values, label='Cox S(t)', color='blue')
    if S_aft is not None:
        ax.plot(S_aft.index, S_aft.values, label='Weibull AFT S(t)', color='green')
    if not math.isnan(summary.get('tstar_cox', np.nan)):
        ax.axvline(summary['tstar_cox'], color='purple', linestyle=':', label=f't* Cox {summary['tstar_cox']:.1f}w')
    if not math.isnan(summary.get('tstar_loss_cox', np.nan)):
```

```
        ax.axvline(summary['tstar_loss_cox'], color='black', linestyle='-', label=f't* loss {summary['tstar_loss_cox']:.1f}w')
    ax.set_title(f"{group_name} (n={len(df_group)}) survival", fontfamily='SimHei')
    ax.set_xlabel("孕周 (weeks)", fontfamily='SimHei')
    ax.set_ylabel("S(t) 未达标概率", fontfamily='SimHei')
    ax.legend(prop={'family': 'SimHei'})
    ax.grid(True, linestyle='--', alpha=0.6)
    fig.savefig(os.path.join(OUTDIR, f"{sanitize_filename(outpref)}_survival.png"), dpi=200, bbox_inches='tight')
    plt.close(fig)
    return summary
# ---------------- Pipeline runner ----------------
def run_pipeline():
    df = read_and_prepare(INPUT_FILE)
    df = rule_bmi_groups(df)
    df = cluster_groups(df, k=3)   # 只保留 k=3 的聚类
    summaries = []
    # rule groups
    for grp in df['BMI_group_rule'].dropna().unique():
        sub = df[df['BMI_group_rule'] == grp]
        if len(sub) < 10:
            print(f"Skip rule group {grp} (n={len(sub)})")
            continue
        print(f"Analyze rule group {grp} (n={len(sub)})")
        s = analyze_group(sub, group_name=f"rule_{grp}", outpref=f"rule_{grp}")
        summaries.append(s)
    # clusters k=3 only
    col = "BMI_k3"
    for lab in sorted(df[col].unique()):
        sub = df[df[col] == lab]
        if len(sub) < 10:
            print(f"Skip cluster k3_{lab} (n={len(sub)})")
            continue
        print(f"Analyze cluster k3_{lab} (n={len(sub)})")
        s = analyze_group(sub, group_name=f"k3_{lab}", outpref=f"k3_{lab}")
        summaries.append(s)
    master = pd.DataFrame(summaries)
    master.to_csv(os.path.join(OUTDIR, "problem3_master_summary.csv"), index=False)
    print(f"Master summary saved to {os.path.join(OUTDIR, 'problem3_master_summary.csv')}")
    # 聚类结果可视化
    print("Creating clustering visualization...")
    features = ["BMI", "weight_kg", "height_cm"]
    X = df[features].fillna(df[features].median())
    scaler = StandardScaler()
    X_scaled = scaler.fit_transform(X)
    fig, axes = plt.subplots(1, 2, figsize=(12, 5))
```

```
    # 聚类分布
    cluster_counts = df['BMI_k3'].value_counts().sort_index()
    axes[0].bar(cluster_counts.index, cluster_counts.values)
    axes[0].set_title('Cluster Distribution (k=3)', fontfamily='SimHei')
    axes[0].set_xlabel('Cluster', fontfamily='SimHei')
    axes[0].set_ylabel('Number of Patients', fontfamily='SimHei')
    # PCA 的可视化
    pca = PCA(n_components=2)
    X_pca = pca.fit_transform(X_scaled)
    scatter = axes[1].scatter(X_pca[:, 0], X_pca[:, 1], c=df['BMI_k3'], cmap='viridis', alpha=0.6)
    axes[1].set_title('PCA Visualization of Clusters (k=3)', fontfamily='SimHei')
    axes[1].set_xlabel('PC1', fontfamily='SimHei')
    axes[1].set_ylabel('PC2', fontfamily='SimHei')
    plt.colorbar(scatter, ax=axes[1])
    plt.tight_layout()
    plt.savefig(os.path.join(OUTDIR, "clustering_visualization_k3.png"), dpi=200, bbox_inches='tight')
    plt.close()
    print("Clustering visualization saved.")
    return master
if __name__ == "__main__":
    master = run_pipeline()
    print(master)
```

附录 8

介绍：问题 4QC 处理

```
% 1. 读取清洗后的数据
data = readtable('problem4_QC 处理后 1.csv', 'VariableNamingRule', 'preserve');
% 提取 Z 值
Z13 = data.("13 号染色体的 Z 值");
Z18 = data.("18 号染色体的 Z 值");
Z21 = data.("21 号染色体的 Z 值");
% 标签：0=正常，1=异常
label = data.("染色体的非整倍体");
%% 2. Z 值分布直方图与箱线图
figure;
% Z13
subplot(3,2,1);
histogram(Z13(label==0), 'Normalization','pdf','FaceColor',[0.3 0.7 1]); hold on;
histogram(Z13(label==1), 'Normalization','pdf','FaceColor',[1 0.4 0.4]);
title('Z13 Histogram'); legend('正常','异常');
subplot(3,2,2);
g = categorical(label, [0 1], {'正常','异常'});
boxplot(Z13, g, 'Colors', [0.3 0.7 1; 1 0.4 0.4]);
title('Z13 Boxplot');
```

```
% Z18
subplot(3,2,3);
histogram(Z18(label==0), 'Normalization','pdf','FaceColor',[0.3 0.7 1]); hold on;
histogram(Z18(label==1), 'Normalization','pdf','FaceColor',[1 0.4 0.4]);
title('Z18 Histogram'); legend('正常','异常');
subplot(3,2,4);
g = categorical(label, [0 1], {'正常','异常'});
boxplot(Z18, g, 'Colors', [0.3 0.7 1; 1 0.4 0.4]);
title('Z18 Boxplot');
% Z21
subplot(3,2,5);
histogram(Z21(label==0), 'Normalization','pdf','FaceColor',[0.3 0.7 1]); hold on;
histogram(Z21(label==1), 'Normalization','pdf','FaceColor',[1 0.4 0.4]);
title('Z21 Histogram'); legend('正常','异常');

subplot(3,2,6);
g = categorical(label, [0 1], {'正常','异常'});
boxplot(Z21, g, 'Colors', [0.3 0.7 1; 1 0.4 0.4]);
title('Z21 Boxplot');
%% 3. 计算 Z_max 和 Z_mean
Zmax = max([Z13, Z18, Z21], [], 2);
Zmean = mean([Z13, Z18, Z21], 2);
%% 4. ROC 曲线和 AUC
% Zmax
[X1,Y1,~,AUC_max] = perfcurve(label, Zmax, 1);
figure;
plot(X1,Y1,'LineWidth',2); grid on;
xlabel('False Positive Rate'); ylabel('True Positive Rate');
title(['ROC for Z_{max}, AUC=' num2str(AUC_max,'%.3f')]);
% Zmean
[X2,Y2,~,AUC_mean] = perfcurve(label, Zmean, 1);
figure;
plot(X2,Y2,'LineWidth',2); grid on;
xlabel('False Positive Rate'); ylabel('True Positive Rate');
title(['ROC for Z_{mean}, AUC=' num2str(AUC_mean,'%.3f')]);
%% 5. QC 指标差异检验
QC_names = {'原始读段数','在参考基因组上比对的比例','重复读段的比例','GC 含量'};
for i = 1:length(QC_names)
x = data.(QC_names{i});
% Mann-Whitney U 检验
p = ranksum(x(label==0), x(label==1));
fprintf('%s: 正常均值=%.2f, 异常均值=%.2f, p=%.4f\n', ...
QC_names{i}, mean(x(label==0),'omitnan'), mean(x(label==1),'omitnan'), p);
end
```

```
%% 6. 输出说明
disp('已生成结果：');
disp('1) Z13/Z18/Z21 的直方图 + 箱线图');
disp('2) Z_max 和 Z_mean 的 ROC 曲线及 AUC');
disp('3) QC 指标在正常 vs 异常的均值 + 显著性检验');
```

附录 9

介绍：问题四相关性系数矩阵与 VIF 计算

```
%% 1. 读取数据
data = readtable('problem4_QC 处理后 1.csv','VariableNamingRule','preserve');

%% 2. 提取需要的特征
features = [ ...
data.("13 号染色体的 Z 值"), data.("18 号染色体的 Z 值"), data.("21 号染色体的 Z 值"), ... % 核心
data.("X 染色体的 Z 值"), data.("X 染色体浓度"), ... % 辅助
data.("原始读段数"), data.("在参考基因组上比对的比例"), data.("重复读段的比例"), ...
data.("GC 含量"), data.("13 号染色体的 GC 含量"), data.("18 号染色体的 GC 含量"), data.("21 号染色体的 GC 含量"), ... % 质量
data.("检测孕周"), data.("孕妇 BMI"), data.("年龄")]; % 个体

feature_names = { ...
'Z13','Z18','Z21','ZX','Xconc', ...
'Reads','MapRate','DupRate','GC', ...
'GC13','GC18','GC21','GA','BMI','Age'};

%% 3. 数值标准化 (均值 0，方差 1)
features_norm = normalize(features);

%% 4. 构造派生特征
Zmax = max(features(:,1:3),[],2);
Zmean = mean(features(:,1:3),2);
GCdev = abs(data.("GC 含量") - 0.5);
GA_BMI = data.("检测孕周") .* data.("孕妇 BMI");

derived_features = [Zmax, Zmean, GCdev, GA_BMI];
derived_names = {'Zmax','Zmean','GCdev','GA_BMI'};

%% 5. 合并特征矩阵
all_features = [features_norm, derived_features];
all_names = [feature_names, derived_names];

%% 6. 计算相关性矩阵
R = corr(all_features,'Rows','pairwise');

figure;
```

```
heatmap(all_names, all_names, R, 'Colormap', parula, 'ColorbarVisible','on');
title('相关性系数热力图');

%% 7. 计算 VIF
VIF = zeros(1,size(all_features,2));
for i = 1:size(all_features,2)
Xi = all_features(:,i);
Xothers = all_features(:, setdiff(1:size(all_features,2), i));
mdl = fitlm(Xothers, Xi);
R2 = mdl.Rsquared.Ordinary;
VIF(i) = 1 / (1 - R2);
end

T = table(all_names', VIF', 'VariableNames', {'Feature','VIF'});
disp('各特征的 VIF 值:');
disp(T);
```

附录 10

介绍：问题四灰区二次分类模型

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import roc_auc_score, roc_curve, confusion_matrix, classification_report
import matplotlib.pyplot as plt
# 1. 读取数据
data = pd.read_csv("problem4_QC 处理后 1.csv")
# 特征选择
features = ["13 号染色体的 Z 值", "18 号染色体的 Z 值", "21 号染色体的 Z 值",
            "X 染色体的 Z 值", "X 染色体浓度",
            "原始读段数", "在参考基因组上比对的比例", "重复读段的比例", "GC 含量",
            "检测孕周", "孕妇 BMI", "年龄"]
X = data[features]
y = (data["染色体的非整倍体"] == 1).astype(int)
# 缺失值填充
X = X.fillna(X.median())
# 2. 划分数据
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y)
# 3. 标准化
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
```

```
X_test_scaled = scaler.transform(X_test)
# 4. 模型
log_reg = LogisticRegression(max_iter=1000, penalty="l2", solver="liblinear")
rf = RandomForestClassifier(n_estimators=200, random_state=42)
log_reg.fit(X_train_scaled, y_train)
rf.fit(X_train_scaled, y_train)
# 5. 预测概率
y_prob_lr = log_reg.predict_proba(X_test_scaled)[:, 1]
y_prob_rf = rf.predict_proba(X_test_scaled)[:, 1
# ===== 分类评估函数 =====
def eval_classifier(y_true, y_prob, threshold, model, name, feature_names=None):
    y_pred = (y_prob >= threshold).astype(int)
    cm = confusion_matrix(y_true, y_pred)
    print(f"\n{name} @ 阈值={threshold}")
    print("混淆矩阵:\n", cm)
    print("\n 分类报告:\n", classification_report(y_true, y_pred, digits=3))

    if name == "逻辑回归":
        coefs = pd.Series(model.coef_[0], index=feature_names)
        print("\n 逻辑回归特征权重（按绝对值排序）:")
        print(coefs.abs().sort_values(ascending=False))
    elif name == "随机森林":
        importances = pd.Series(model.feature_importances_, index=feature_names)
        print("\n 随机森林特征重要性（排序）:")
        print(importances.sort_values(ascending=False))
# 6. 阈值评估
eval_classifier(y_test, y_prob_lr, 0.8, log_reg, "逻辑回归", features)
eval_classifier(y_test, y_prob_rf, 0.13, rf, "随机森林", features)
# 7. ROC 曲线
fpr_lr, tpr_lr, _ = roc_curve(y_test, y_prob_lr)
fpr_rf, tpr_rf, _ = roc_curve(y_test, y_prob_rf)
auc_lr = roc_auc_score(y_test, y_prob_lr)
auc_rf = roc_auc_score(y_test, y_prob_rf)
plt.figure(figsize=(6, 5))
plt.plot(fpr_lr, tpr_lr, label=f"LogReg (AUC={auc_lr:.3f})")
plt.plot(fpr_rf, tpr_rf, label=f"RandomForest (AUC={auc_rf:.3f})")
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel("False Positive Rate")
plt.ylabel("True Positive Rate")
plt.title("ROC Curves")
plt.legend()
plt.show()
```

附录 11

介绍：问题四特征权重排序

```
%% 数据输入
features = { ...
'X 染色体浓度','年龄','13 号染色体的 Z 值','X 染色体的 Z 值','原始读段数', ...
'21 号染色体的 Z 值','GC 含量','检测孕周','在参考基因组上比对的比例','孕妇 BMI', ...
'18 号染色体的 Z 值','重复读段的比例'};
% 逻辑回归权重（按绝对值）
logistic_weights = [0.918450,0.471509,0.382230,0.335461,0.321463, ...
0.321018,0.207482,0.170056,0.137542,0.132367, ...
0.037182,0.006208];
% 随机森林特征重要性
rf_importance = [0.161960,0.099899,0.088964,0.077211,0.061235, ...
0.074159,0.063205,0.068109,0.061504,0.041915, ...
0.043041,0.158796];
%% 合并数据为表格，便于排序
T = table(features', logistic_weights', rf_importance', ...
'VariableNames', {'Feature','Logistic','RandomForest'});
% 按逻辑回归权重排序（也可以改成 RF 排序）
T = sortrows(T, 'Logistic', 'descend');
%% 绘制条形图
figure;
barh(categorical(T.Feature), [T.Logistic, T.RandomForest], 'grouped');
xlabel('特征权重 / 重要性');
ylabel('特征');
legend({'逻辑回归','随机森林'}, 'Location','bestoutside');
title('逻辑回归 vs 随机森林 特征重要性对比');
% 美化
set(gca, 'FontSize', 12);
grid on;
```

附录 12

介绍：问题一多元回归模型的 python 代码

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
from statsmodels.graphics.gofplots import qqplot
from sklearn.model_selection import KFold, cross_val_score
from sklearn.linear_model import LinearRegression
from sklearn.metrics import make_scorer, mean_squared_error, r2_score
from statsmodels.stats.diagnostic import het_white, het_breuschpagan
# === 1. 读取数据 ===
df = pd.read_excel("cleaned.xlsx")
```

```
df_male = df[df['Y_conc'].notna()].copy()
df_male['log_Y_conc'] = np.log(df_male['Y_conc'] + 1e-10)
# 因变量
y = df_male["log_Y_conc"].astype(float)
# 自变量：BMI + 年龄 + 胎儿健康 + 孕周
X = df_male[["BMI_raw", "age", "fetus_healthy", "GA_weeks"]].copy()
# 处理分类变量 fetus_healthy（是/否 → 1/0）
X["fetus_healthy"] = X["fetus_healthy"].map({"是": 1, "否": 0}).astype(float)
# 添加常数项
X = sm.add_constant(X)
# === 2. 建立 OLS 模型 ===
model = sm.OLS(y, X).fit(cov_type="HC3")
print(model.summary())
# === 3. 残差诊断 ===
residuals = model.resid
fitted = model.fittedvalues
# (1) QQ 图
qqplot(residuals, line="s")
plt.title("QQ Plot of Residuals")
plt.show()
# (2) 残差 vs 拟合值图
plt.scatter(fitted, residuals, alpha=0.6)
plt.axhline(y=0, color="red", linestyle="--")
plt.xlabel("Fitted values")
plt.ylabel("Residuals")
plt.title("Residuals vs Fitted")
plt.show()
# === 4. 交叉验证 (10 折) ===
kf = KFold(n_splits=10, shuffle=True, random_state=42)
lin_reg = LinearRegression()
mse_scores = cross_val_score(
    lin_reg, X.drop(columns="const"), y,
    scoring=make_scorer(mean_squared_error, greater_is_better=False),
    cv=kf
)
r2_scores = cross_val_score(
    lin_reg, X.drop(columns="const"), y,
    scoring="r2",
    cv=kf
)
print("\n=== 交叉验证结果 (10 折) ===")
print(f"平均 MSE: {-np.mean(mse_scores):.4f}")
print(f"平均 R² : {np.mean(r2_scores):.4f}")
# 可视化交叉验证结果
```

```
plt.figure(figsize=(6,4))
plt.boxplot([ -mse_scores, r2_scores ], labels=["MSE", "R² "])
plt.title("Cross-validation Results (10-fold)")
plt.show()
# === 5. 异方差检验 ===
white_test = het_white(residuals, model.model.exog)
bp_test = het_breuschpagan(residuals, model.model.exog)
print("\nWhite 异方差检验: p-value =", white_test[1])
print("Breusch-Pagan 异方差检验: p-value =", bp_test[1])
```